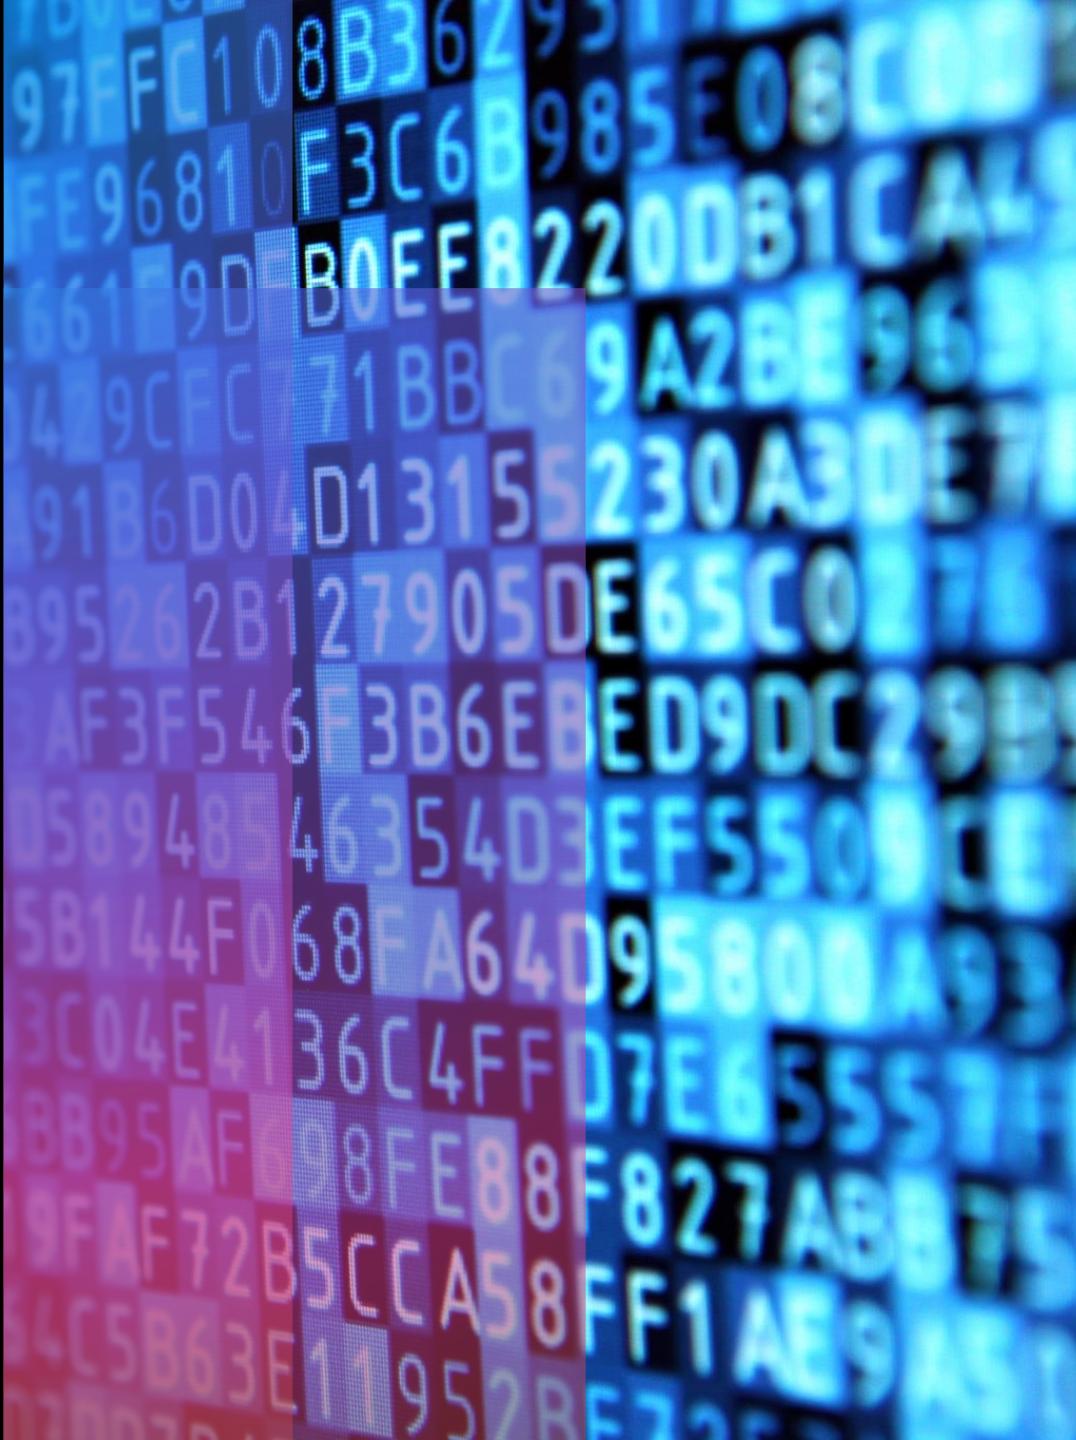
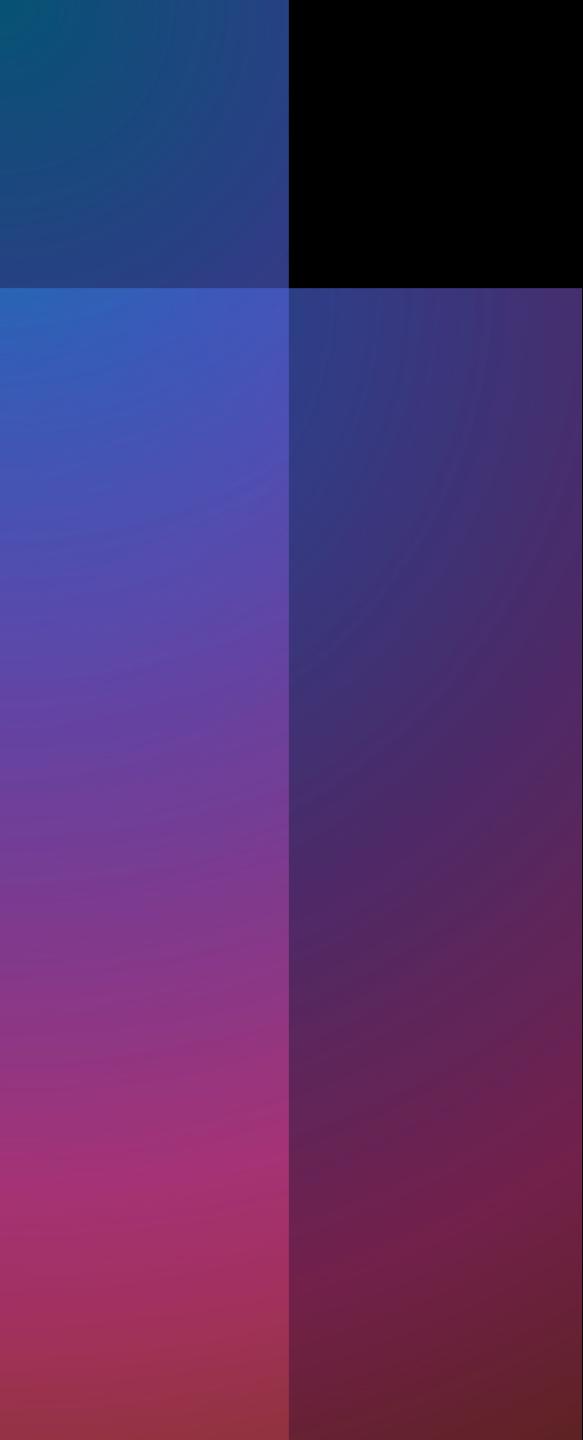


# [Platzhalter :in]

VERSION 1.0





# **Data Science Methods of AI Machine Learning Deep Learning**

# Ein Vorwort...

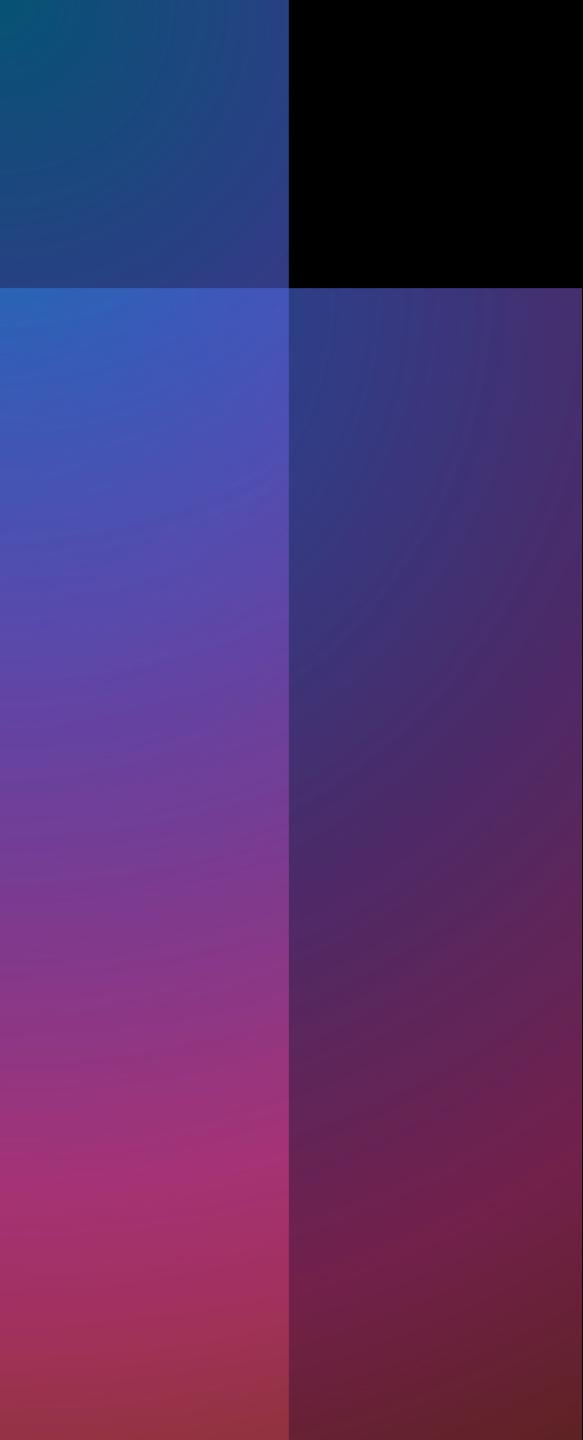
Worauf diese Präsentation **NICHT** basiert:

- Verschwörungen
- Angstmache, dass künstliche Intelligenz-en bald die Weltherrschaft übernehmen

Was ihr hier findet:

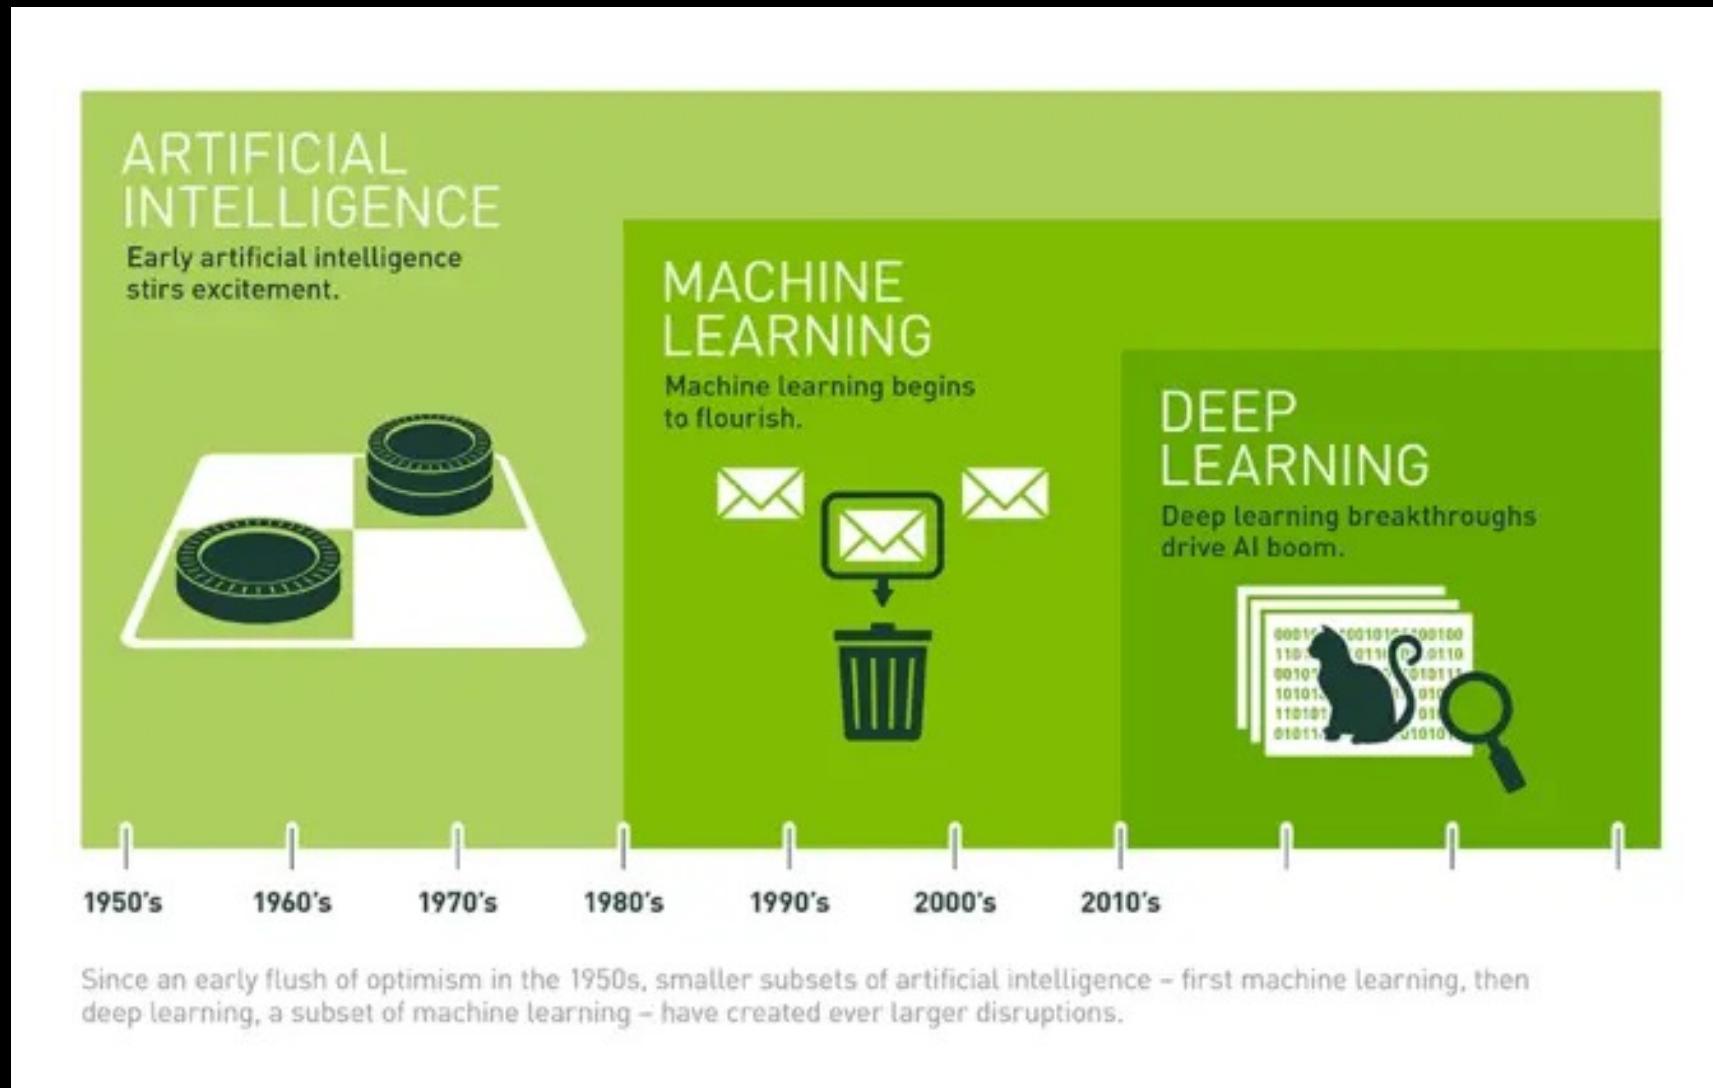
- Hilfreiche Infos
- Spiel, Spaß und Spannung
- Babytiere

Alle weiteren Quellen sind in der Präsentation oder im Quellverzeichnis zu finden ;)

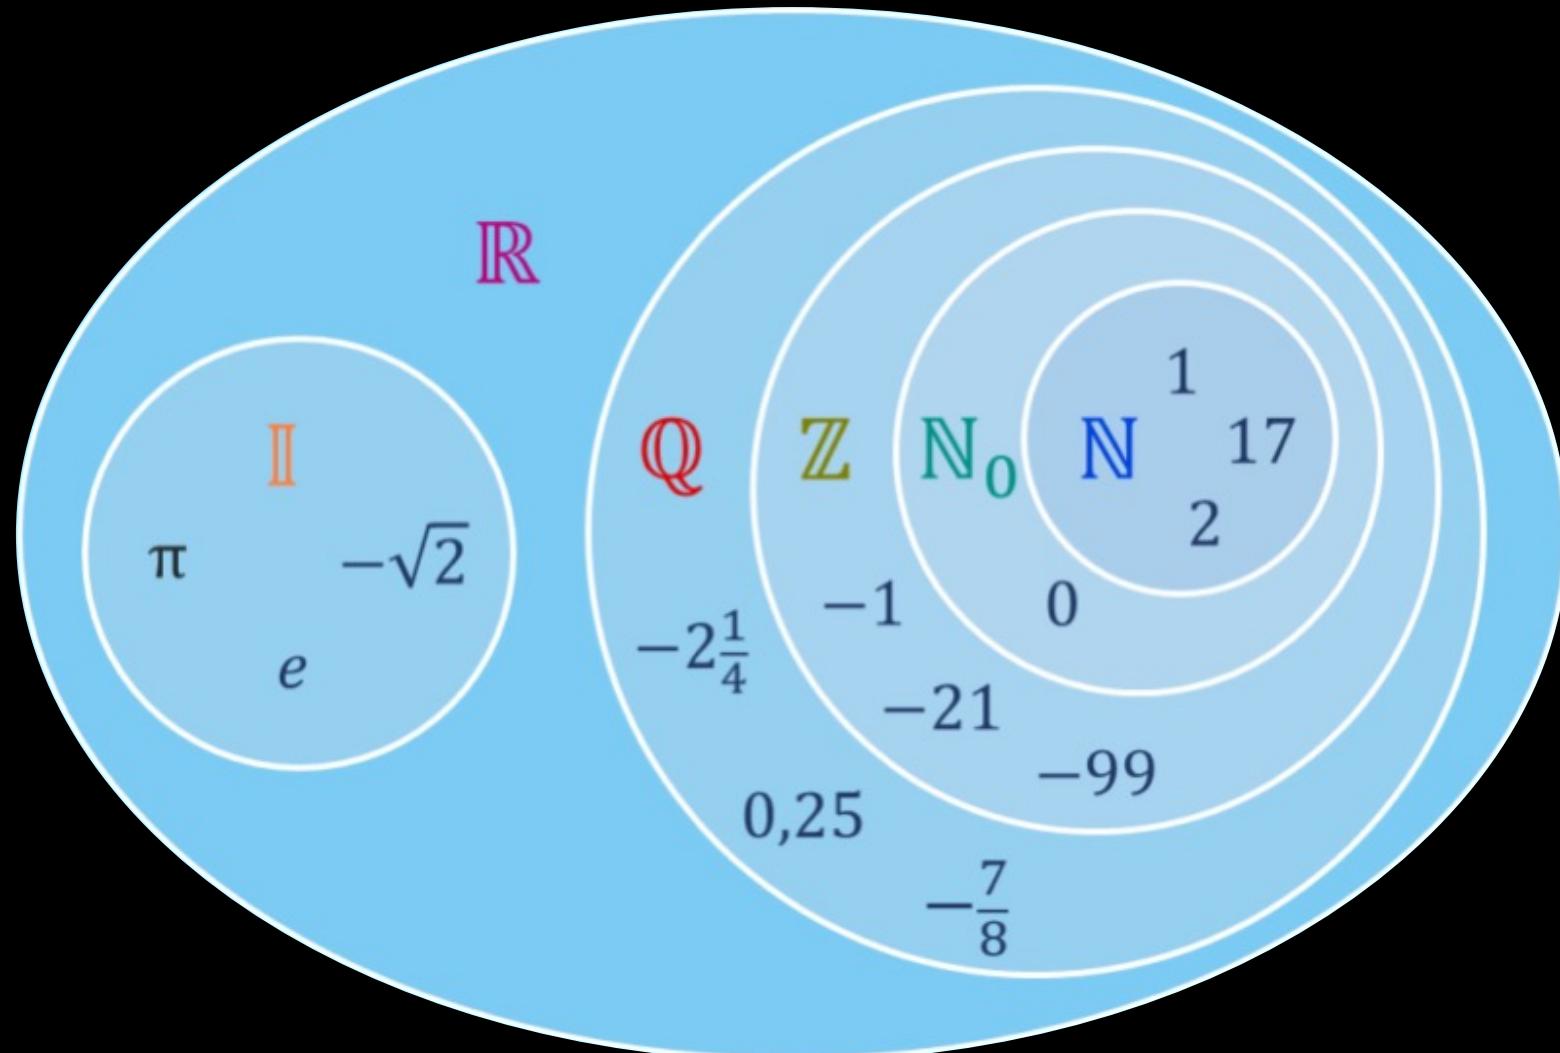


# 1. Äpfel und Birnen

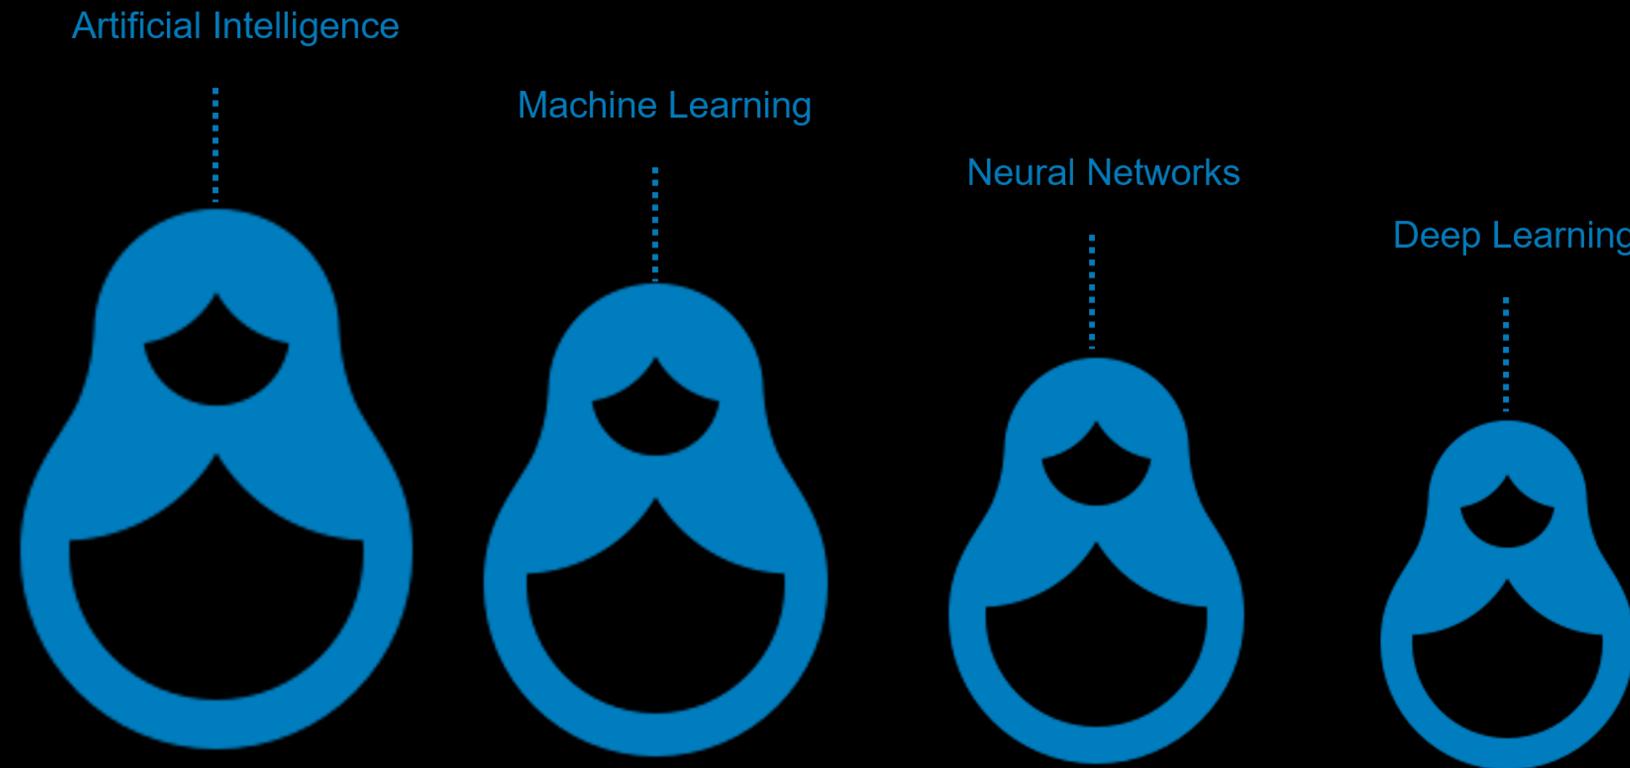
# ...sind beides Früchte, aber nicht dieselbe

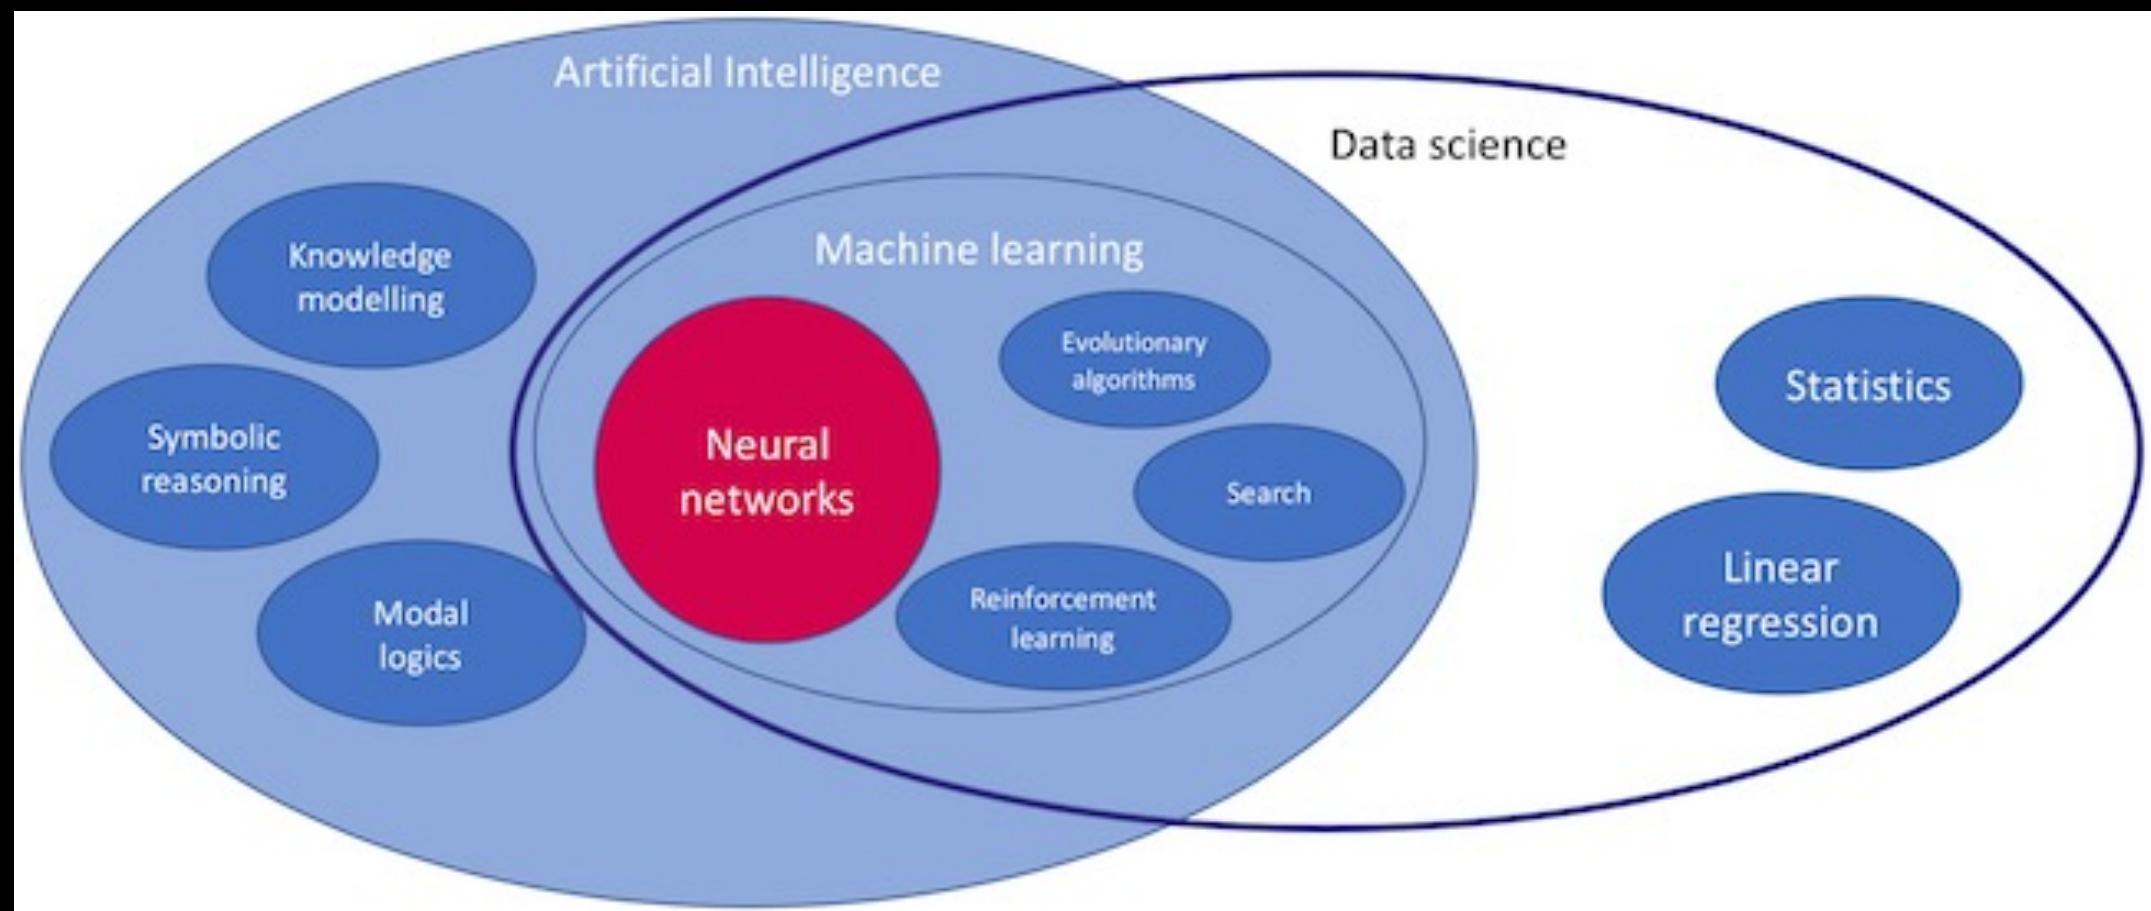


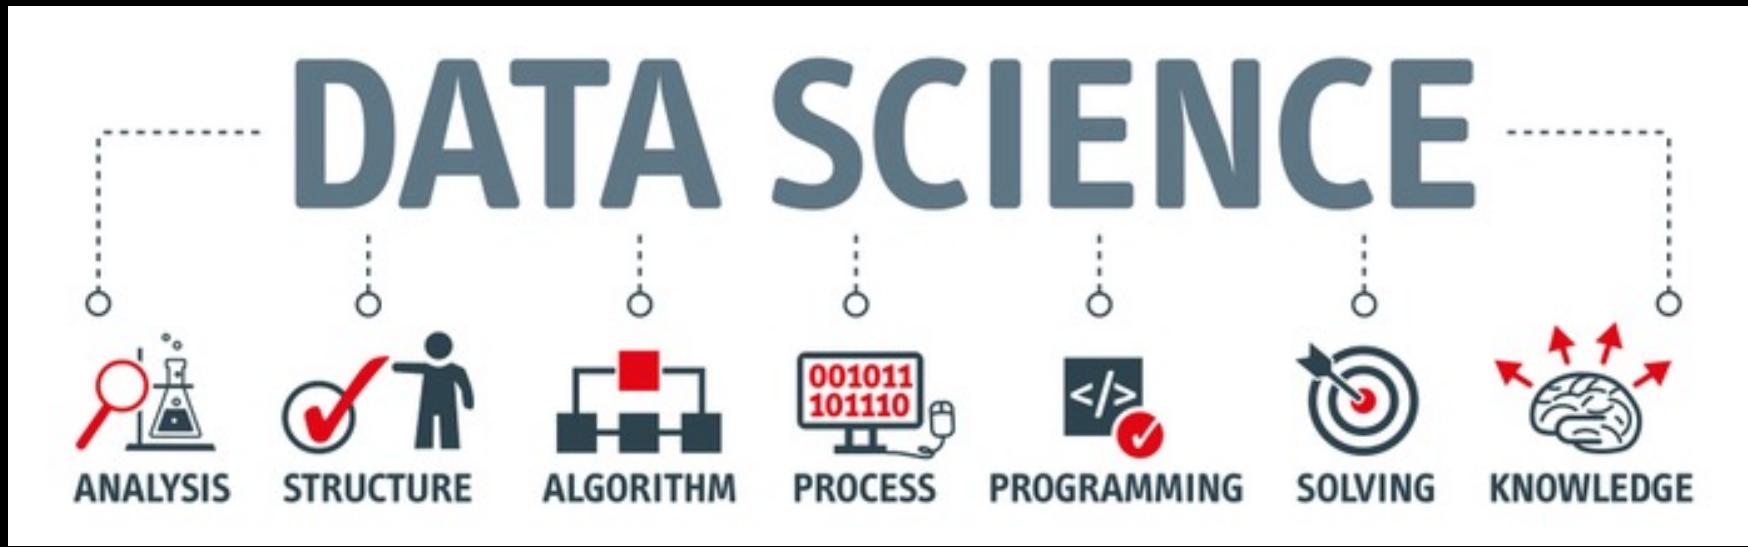
# WH: Logik und Berechenbarkeit



# Dasselbe Mental Model kann man auch auf AI, ML und co. anwenden:



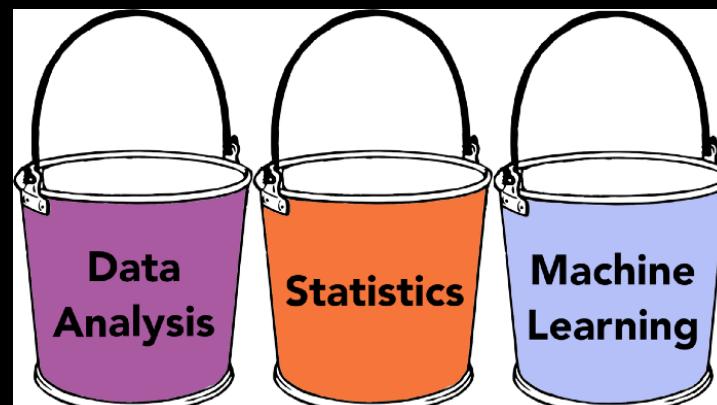




# 1.1 Data Science

# Um was geht es in Data Science?

- Beschäftigt sich mit Daten, meist in “rohem” Zustand
- Daten müssen genau betrachtet, bereinigt, sortiert – d.h. **analysiert** werden
- Im Grunde stützt sich Data Science auf drei wichtige Aspekte:

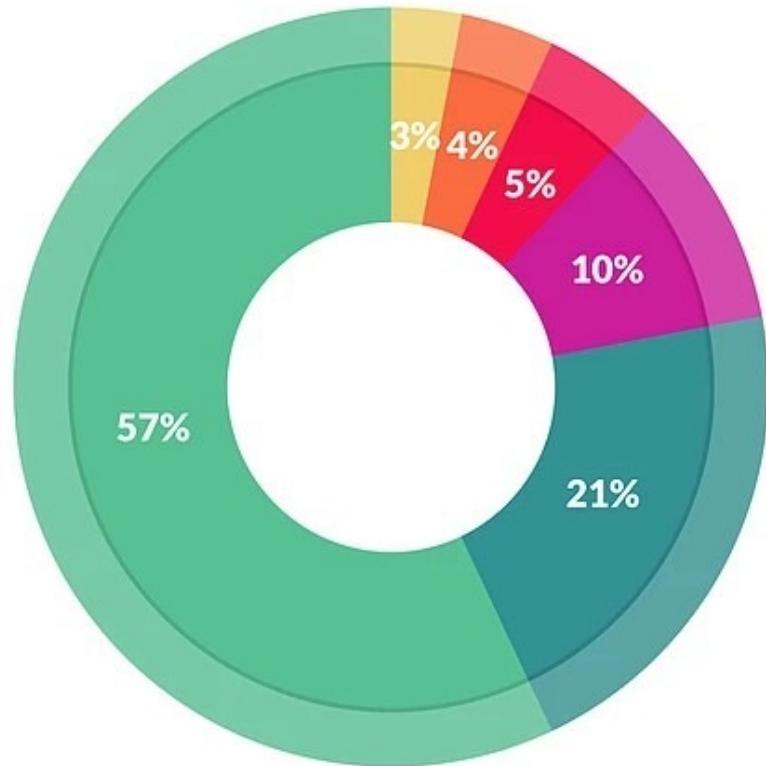


# 1.1.1 Data Analysis

- Ziel ist es, tiefere Einblicke zu einem Thema zu erhalten
- Das Augenmerk liegt auf der Hypothese: Wird diese durch die gesammelten Daten gestützt (validiert) oder widersprechen die Daten der Hypothese (falsifiziert)?
- Integrität beim Forschen ist eine der wichtigsten Eigenschaften: Besonders dann, wenn die Ergebnisse den eigenen Idealen widersprechen (Bsp.:  
<https://www.youtube.com/watch?v=aOYrVM5bTno>)
- WICHTIG: **Kausalität != Korrelation**  
Kausalitäten existieren wesentlich seltener als man denkt;  
Korrelationen kann man jedoch immer herstellen, selbst wenn es keinen Sinn macht  
(Spurious Correlations)
- Data Analysts bzw. Data Scientists bereinigen Daten (“**Data Cleansing**” oder auch “**Data Scrubbing**” genannt)

- Daten sind nicht immer konsistent, akkurat, vollständig,...
- Ein großer Teil der Arbeit von Data Scientists ist es also, sich um die Verlässlichkeit von Daten zu kümmern
- “**Garbage in, garbage out.**”
- Füttert man einen ML-Algorithmus mit “Garbage data”, erhält man ein entsprechendes Resultat
- WH aus Logik & Berechenbarkeit:  
*“Ex falso quodlibet.”* – Aus einem logisch (und faktisch) falschen Satz folgt jede beliebige Aussage, **nur keine Wahre**  
→ “Die Erde ist eine Scheibe, daher ist Sonntag ein ungerader Montag.”

# Laut einer Umfrage...



What's the least enjoyable part of data science?

- *Building training sets:* 10%
- *Cleaning and organizing data:* 57%
- *Collecting data sets:* 21%
- *Mining data for patterns:* 3%
- *Refining algorithms:* 4%
- *Other:* 5%

Image Credits: whatsthebigdata.com

## 1.1.2 Statistik in Data Science

- Data Scientists **identifizieren** die **wichtigsten Features**, indem sie **viele statistische Tests** durchführen
- **Normalisieren** und **Skalieren** von Features
  - Normalisieren: Die **Daten sind normalverteilt** und sollen als Glockenkurve dargestellt werden
  - Skalieren: **Range der Daten wird verändert und so angepasst**, dass Daten innerhalb einer Range liegen (z. B. von 0 – 100)

- **Anpassung** der Daten und **Identifizierung** der passenden mathematischen **Modelle**
  - Verifzieren von Resultaten mit geeigneten “**Accuracy Measurement Scales**”
- Jeder Schritt der Datenverarbeitung beinhaltet statistische Methoden!

## 1.1.3 Sprachen und Entwicklungsumgebungen

- **Sprachen:**

- R
- Python
- SQL

...und andere, je nach Anwendungsfall!

- **Entwicklungsumgebungen:**

- IDEs wie DataSpell oder PyCharm von Jetbrains
- Spyder
- Jupyter Notebook
- Google Colab (vor allem hilfreich, wenn man keine eigene GPU hat)

# Ressourcen zu diesem Kapitel und Data Science:

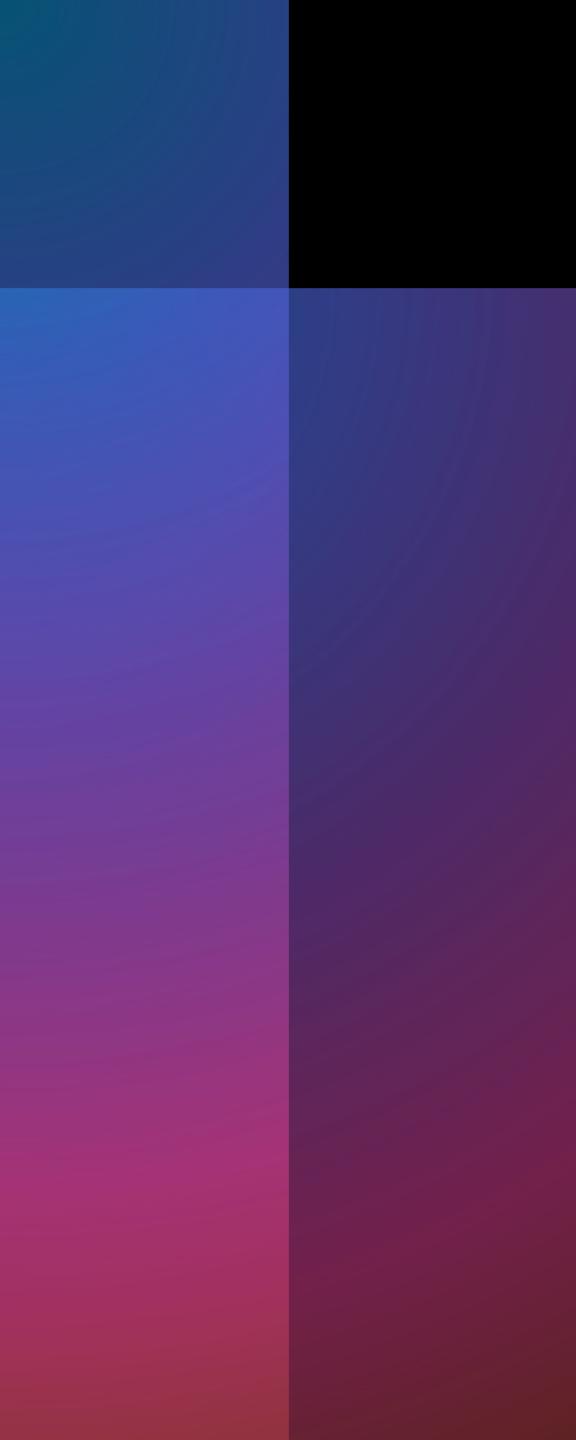
- <https://www.interviewbit.com/blog/python-vs-r/>
- <https://towardsdatascience.com/introduction-to-statistics-e9d72d818745>
- <https://datascience.virginia.edu/news/how-much-do-data-scientists-need-know-about-statistics>
- <https://ai.google/education/>
- [https://de.wikipedia.org/wiki/Ex\\_falso\\_quodlibet](https://de.wikipedia.org/wiki/Ex_falso_quodlibet)

# Ressourcen zu diesem Kapitel und Data Science:

- <https://www.coursera.org/articles/data-science-vs-machine-learning>
- <https://developers.google.com/machine-learning/data-prep/transform/normalization>
- <https://towardsdatascience.com/understand-data-normalization-in-machine-learning-8ff3062101f0>
- <https://towardsai.net/p/data-science/scaling-vs-normalizing-data-5c3514887a84>

# PAUSE ☺





1.2

# Artifical Intelligence & Methods of AI

## 1.2.1 Einführung - KI ist definitionslos

Ja, richtig gelesen. **Es gibt keine offizielle Definition** dazu, was AI (oder zu Deutsch: KI) ist.

Stattdessen wird dieser Bereich immer wieder aufs Neue umdefiniert, erweitert oder sogar gekürzt.

Es ist zudem schwer, allgemeingültig zu definieren, welche Tasks “leicht” sind und welche “schwer”.

Aber wieso ist das so?

- Beispiel 1:

Stell dir vor, du gehst an einem Feld entlang, worauf Apfelbäume stehen. Du siehst, wie bereits schön saftige Äpfel dranhängen und hast das Bedürfnis, dir einen davon zu nehmen (wir gehen davon aus, dass das OK ist ;-)). Du bleibst stehen, hebst den Arm und greifst nach einem Ast, den du fassen kannst. Dann ziehst du behutsam ebenjenen Ast zu dir heran und greifst mit der anderen Hand den Apfel.

Nom.

- Beispiel 2:

Du sitzt in einer Halle mit anderen Menschen. Es herrscht keine Pandemie, trotzdem tragen rücksichtsvollerweise einige Personen eine Maske, um niemanden mit Erkältungsviren anzustecken ;-)  
Alle starren konzentriert auf die schwarzen bzw. weißen Figuren vor sich. Es ist relativ ruhig.

Du schaust auf deine Figuren und anschließend auf jene, die du bereits verloren hast. Dann wandert dein Blick auf die Figuren deines Gegenübers. In deinem Kopf rattert es regelrecht und du versuchst, jeden möglichen Zug deines Gegenübers gedanklich durchzuspielen. Du gehst eine Wahrscheinlichkeit nach der anderen durch, immer und immer wieder.

- Was davon ist eurer Meinung nach nun die “schwierigere” Aufgabe?

- Was davon ist eurer Meinung nach nun die “schwierigere” Aufgabe?
- Viele Menschen würden das 2. Beispiel wählen
- Für eine KI-Anwendungen ist es jedoch ausnahmslos das 1. Beispiel

Warum?

- Eine KI kann sehr viele Berechnungen in sehr kurzer Zeit machen, mehr als die allermeisten Menschen
- Allerdings kann eine KI keinen Apfel greifen, selbst wenn sie im Körper eines Roboters steckt. Motorische Fähigkeiten (insbesondere feinmotorische) sind nach wie vor schwer zu realisieren und bedeuten einen **(enorm) hohen (Kosten-)Aufwand bzgl. Material und Programmierung**
- Außerdem – und das ist der wichtigste Punkt – **empfindet eine KI keine “Lust”**; es existiert kein Impuls, um beispielsweise einen Apfel zu essen. Es **fehlt einer KI** daher gänzlich **an Bewusstein, Autonomie und selbstreflektierter Anpassungsfähigkeit**

# Und da wär noch das Thema mit der Intelligenz...

- Wenn wir uns mit diesen Themen beschäftigen, taucht zwangsläufig die Frage auf:  
WAS ist eigentlich Intelligenz? WAS ist “intelligentes Verhalten”?
- Können wir uns hier den Mensch als Vorbild nehmen? Ja? Nein?

WHEN A USER TAKES A PHOTO,  
THE APP SHOULD CHECK WHETHER  
THEY'RE IN A NATIONAL PARK...

SURE, EASY GIS LOOKUP.  
GIMME A FEW HOURS.

...AND CHECK WHETHER  
THE PHOTO IS OF A BIRD.

I'LL NEED A RESEARCH  
TEAM AND FIVE YEARS.



IN CS, IT CAN BE HARD TO EXPLAIN  
THE DIFFERENCE BETWEEN THE EASY  
AND THE VIRTUALLY IMPOSSIBLE.

# Key Takeaways

- KI bzw. KI-Methoden haben **keine klare Definition**
- Intelligenz ist **weder** bei Menschen noch bei KI-Methoden **eindimensional**, sondern **mannigfaltig**
- In Sachen KI gibt es **kein Schwarz-Weiß-Denken**:  
Es gibt eine Vielzahl an Methoden, die ein “klein wenig” an “KI-heit” beinhalten, aber vollständig daraus bestehen  
→ Ein Spektrum an “KI-Methoden”
- **KI ist keinzählbares Nomen!**  
KI stellt eine Fachrichtung dar – man würde auch nicht sagen: “eine Physik”. Wer professionell klingen möchte, spricht von “**KI-Methoden**” bzw. “**Methods of AI**”

# Zeit für ein kleines Quiz ;)

Sind die folgenden Beispiele KI-Methoden?

- Ein Spreadsheet, mit dem man die Summe und andere vordefinierte Funktionen von gegebenen Daten berechnen kann
- Vorschläge und Empfehlungen von Videos auf Youtube
- Ein GPS-Navigationssystem, um die schnellste Route zu finden

# Zeit für ein kleines Quiz ;)

Sind die folgenden Beispiele KI-Methoden?

- Ein Spreadsheet, mit dem man die Summe und andere vordefinierte Funktionen von gegebenen Daten berechnen kann | **Nein**
- Vorschläge und Empfehlungen von Videos auf Youtube | **Ja**
- Ein GPS-Navigationssystem, um die schnellste Route zu finden | **Ja | Nein | Jein**

# PAUSE ☺



## 1.2.2 Was ist AI?

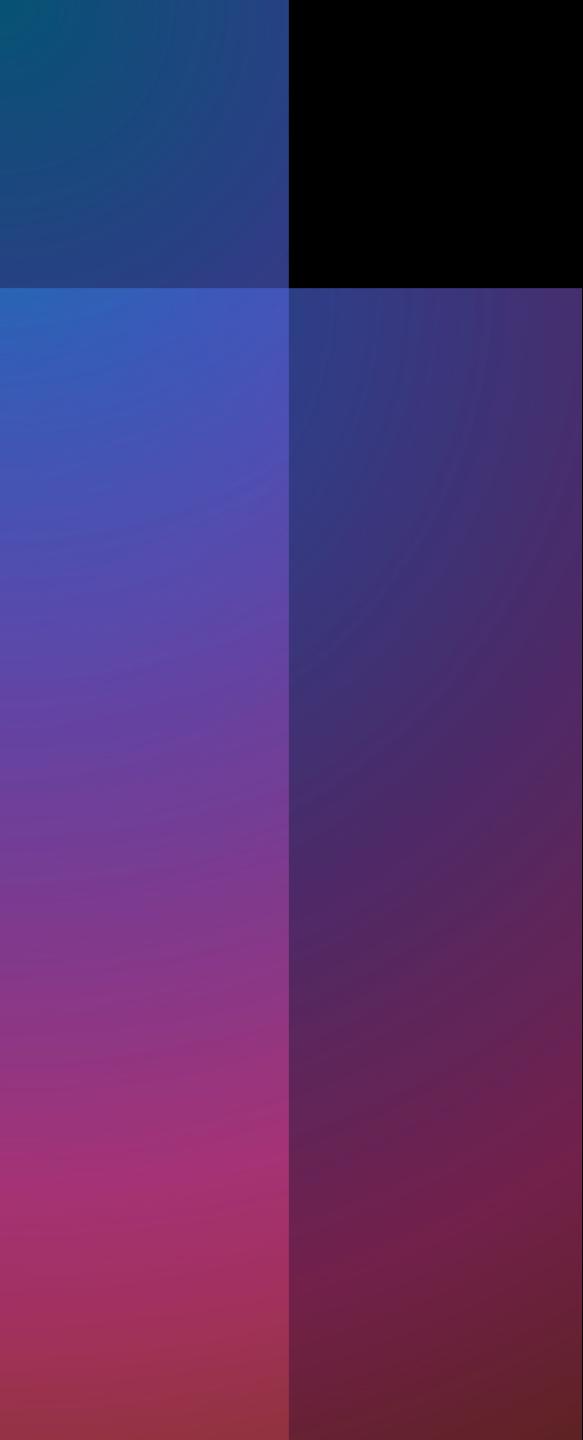
- “*Artificial intelligence leverages computers and machines to mimic the problem-solving and decision-making capabilities of the human mind.*”  
– IBM
- Es gibt derzeit **zwei Typen von AI**:
  - **Weak AI** (auch “Narrow AI” oder “Artificial Narrow Intelligence (**ANI**)” genannt)
  - **Strong AI** (auch “General AI”, “Artificial General Intelligence” oder “Artificial Super Intelligence (**ASI**)” genannt)

- **ANI**: Kommen in unserem täglichen Leben mittlerweile ständig vor, in Form von Algorithmen, die uns Musik, Produkte oder Videos empfehlen;  
z. B.: Amazon's Alexa, Apple's Siri oder autonome Vehikel
- **ASI**: Sind ein theoretisches Konstrukt; hätte mind. dieselben geistigen Kapazitäten wie ein (gesunder) erwachsener Mensch, ein Bewusstsein, könnten lernen, jegliche Probleme lösen und in die Zukunft planen

## 1.2.3 Anwendungen von AI Methods

Nur um die Wichtigsten zu nennen:

- Speech recognition (Spracherkennung)
- Customer service
- Computer vision
- Recommendation engines
- Automated stock trading (Automatisiertes Handeln von Aktien)
- Fraud detection (Betrugsaufdeckung)



# 1.3 The History of AI

## 1.3.1 Ein kurzer Überblick

- Erstmalige Gedanken und Vorstellungen zu künstlicher Intelligenz tauchen in der Geschichte vor ungefähr 2700 Jahren auf (wahrscheinlich gab es aber auch in anderen Kulturen und Ländern dazu bereits Theorien)
- Der erste konkret beschriebene “Roboter” taucht in der Erzählung “Die Geschichte von Talos” von Hesiod auf
- Talos ist ein Bronzemann, an dessen Kopf ein Schlauch befestigt ist, der bis zu den Füßen geht und eine “göttliche” Flüssigkeit durch dessen Körper befördert – das sog. “Ichor”

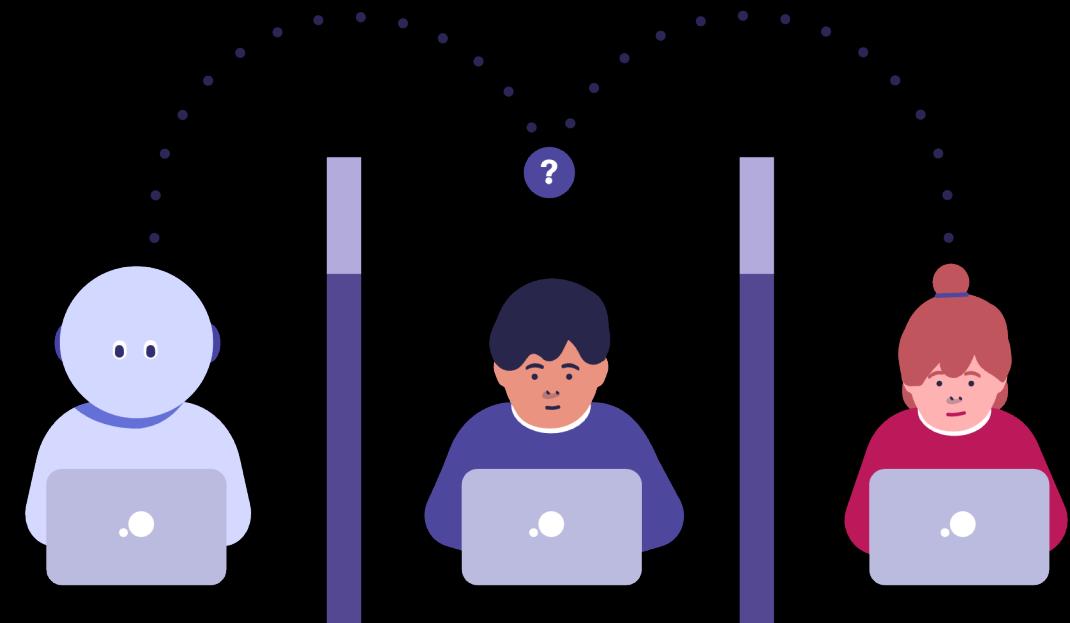
- Andere Beispiele in der griechischen Mythologie sind u.a. die “goldenen Dienerinnen”, welche im Grunde Automaten, dh eigenständig bewegende Frauen sind und die mit “göttlichem Wissen” ausgestattet wurden
- Pandora wird auch gern als “künstliche Intelligenz” bezeichnet, da sie mit dem Ziel, Verderben über die Menschheit zu bringen, kreiert wurde

## 1.3.2 Turing, Pitts & Rosenblatt

- Alan Turing war ein englischer Mathematiker und Logiker
- Wird oft als Begründer der Informatik bezeichnet
- Die Turingmaschine spielt noch heute in der theoretischen Informatik eine bedeutende Rolle
- Auf ihn ist der "Turing Test" zurückzuführen

# Ablauf: Turing Test

- Ein Mensch ist Fragesteller:in.
- Es gibt noch zwei weitere Spieler:innen.
- Die Spieler:innen tauschen schriftlich (in einem Chat) Nachrichten miteinander aus.
- Wenn der/die Fragesteller:in nicht mehr unterscheiden kann, wer von den Spieler:innen ein Mensch und wer ein Computer ist, hat der Computer gewonnen und den Turing Test bestanden.



# Das Problem mit dem Turing Test

- Der Turing Test wird zurecht dafür kritisiert, dass hier kein "echtes" intelligentes Verhalten gezeigt wird, sondern lediglich imitiert
- Es geht also primär darum, dass sich ein Computer wie ein Mensch verhält, und nicht, dass er tatsächliche Intelligenz besitzt
- Intelligenz ist jedoch nicht einhergehend mit intelligentem Verhalten
- Ein Beispiel dafür ist das Gedankenexperiment des "Chinesischen Zimmers"

- Eine Person A ist alleine in einem geschlossenen Raum. Diese Person A kann **kein** chinesisch.
- Außerhalb des Zimmers gibt es eine Person B, die Nachrichten durch einen Briefschlitz schieben kann. Diese Nachrichten sind auf chinesisch verfasst.
- In dem Zimmer befindet sich ein Handbuch, in dem detailliert beschrieben steht, wie die eingesperrte Person A auf die Nachrichten antworten kann.
- Die Person B außerhalb des Zimmers erhält somit sinnvolle Antworten auf ihre Fragen oder Aussagen auf chinesisch und erhält den Eindruck, als ob sie sich mit der eingesperrten Person A tatsächlich unterhalten würde.
- Das bedeutet, eine Maschine kann sich zwar intelligent bzw. menschlich verhalten, kann aber selber keine Intelligenz besitzen – oder eben ein “Bewusstsein”.

# Pitts & McCulloch

- Walter Pitts und Warren McCulloch schrieben eines der bedeutendsten, wenn nicht DAS bedeutendste Paper zur logischen Funktionsweise von Neuronen: “A Logical Calculus of Ideas Immanent in Nervous Activity”, welches sie 1943 im “Bulletin of Mathematical Biophysics” veröffentlichen
- Neuronen mit einem ausreichend hohem “Threshold” feuern erst dann, wenn alle Inputs sich gleichermaßen verhalten, also dem logischen “AND”-Zustand entsprechen würden.
- *“Because of the ‘all-or-none’ character of nervous activity neural events and the relations among them can be treated by means of propositional logic. [...] for any logical expression satisfying certain conditions, one can find a net behaving in the fashion it describes.”*

- In den 50er-Jahren wurde experimentell jedoch gezeigt, dass Neuronen nicht “so einfach” auf diese relativ simplen, logischen Aussagen zu reduzieren sind
- Nichtsdestotrotz ebnete dieses Paper und darauffolgende den Weg, auf maschineller Ebene eine Nachahmung des Gehirns vorzunehmen
- Wichtig mitzunehmen: **Neuronale Netze im menschlichen Gehirn sind wesentlich komplexer und komplizierter und haben mit den maschinellen NN nicht viel gemein, außer einem vereinfachten Konzept von Informationsübertragung!**

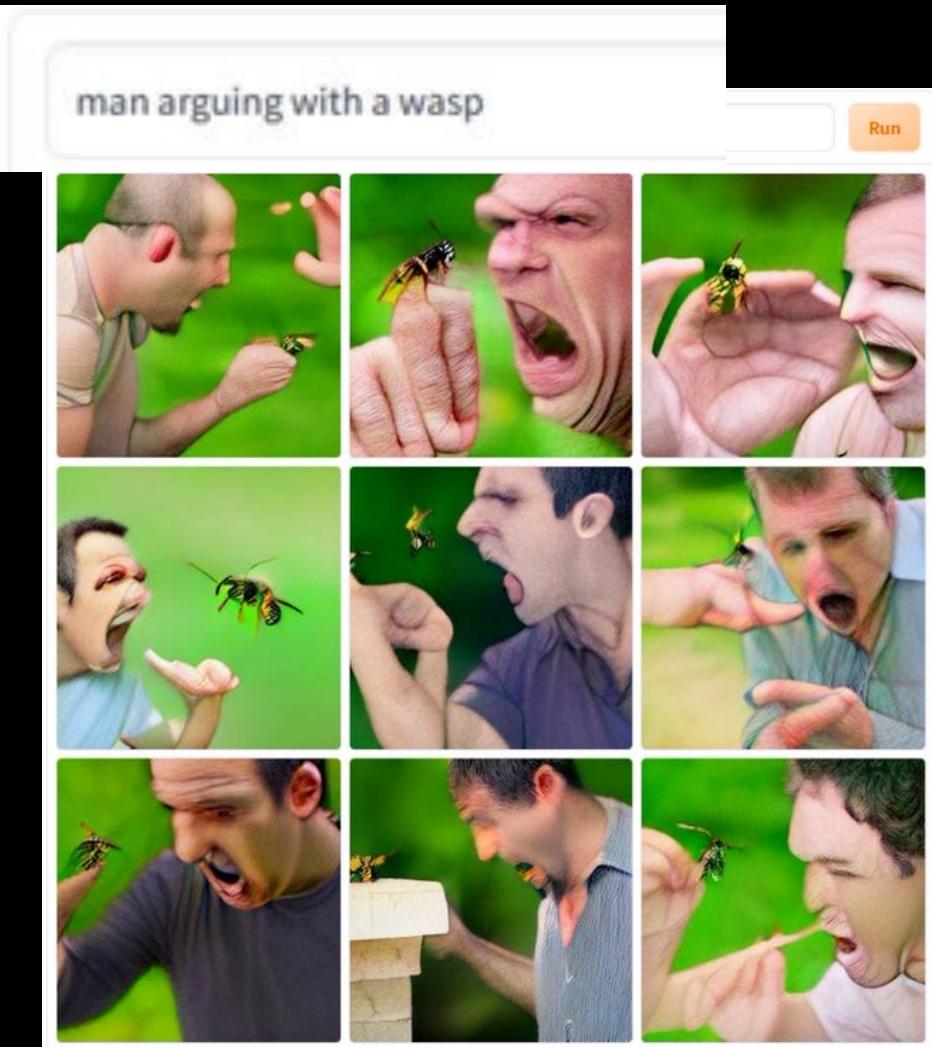
# Frank Rosenblatt und das Perceptron

- Frank Rosenblatt war ein amerikanischer Psychologe und war im Bereich von künstlicher Intelligenz tätig
- Er wird auch manchmal als Begründer des Forschungsfelds von Deep Learning bezeichnet
- Rosenblatt arbeitete mit einem Perceptron – ein Algorithmus, der auf supervised learning basiert und binär klassifiziert (0, 1)
- Die erste Implementierung des Perceptrons wurde 1958 von Rosenblatt vorgenommen
- Das Perceptron ist eine Erfindung von McCulloch und Pitts



# OpenAI's DALL-E mini

## DALL-E mini



A bottle of Ranch Dressing testifying in court

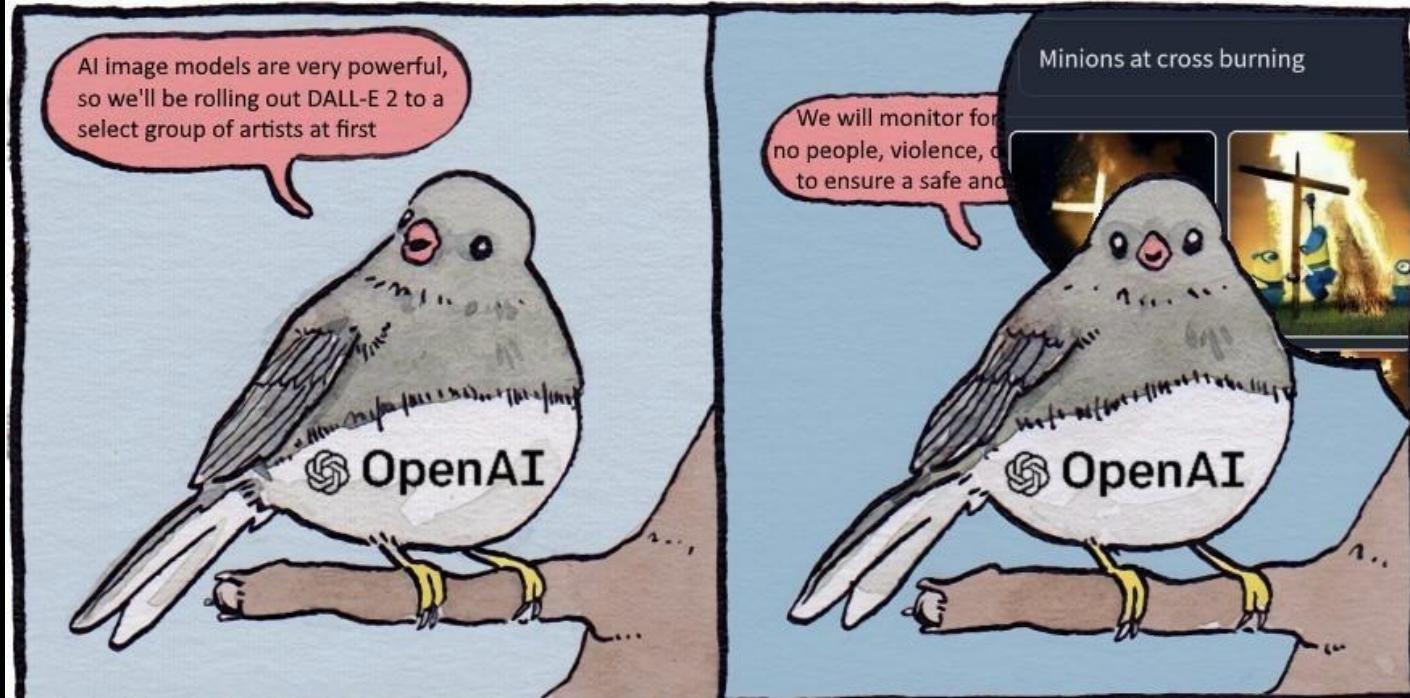
Run

This block contains a 4x3 grid of twelve images. The top row shows a bottle of ranch dressing on a table in a courtroom, with several people visible in the background. The bottom row shows a person's hand holding the same bottle of ranch dressing. The middle two rows show the bottle on the table again, with the person's hand holding it in the foreground. The background shows a courtroom with wooden paneling and spectators.

CCTV yoda robbing a store

Run

This block contains a 4x3 grid of twelve surveillance camera frames. The frames show a person dressed as Yoda walking through a grocery store aisle, interacting with shelves and products. The store has typical grocery items like cereal boxes and bags of chips on the shelves. The lighting is consistent with indoor surveillance footage.



# PAUSE 😊

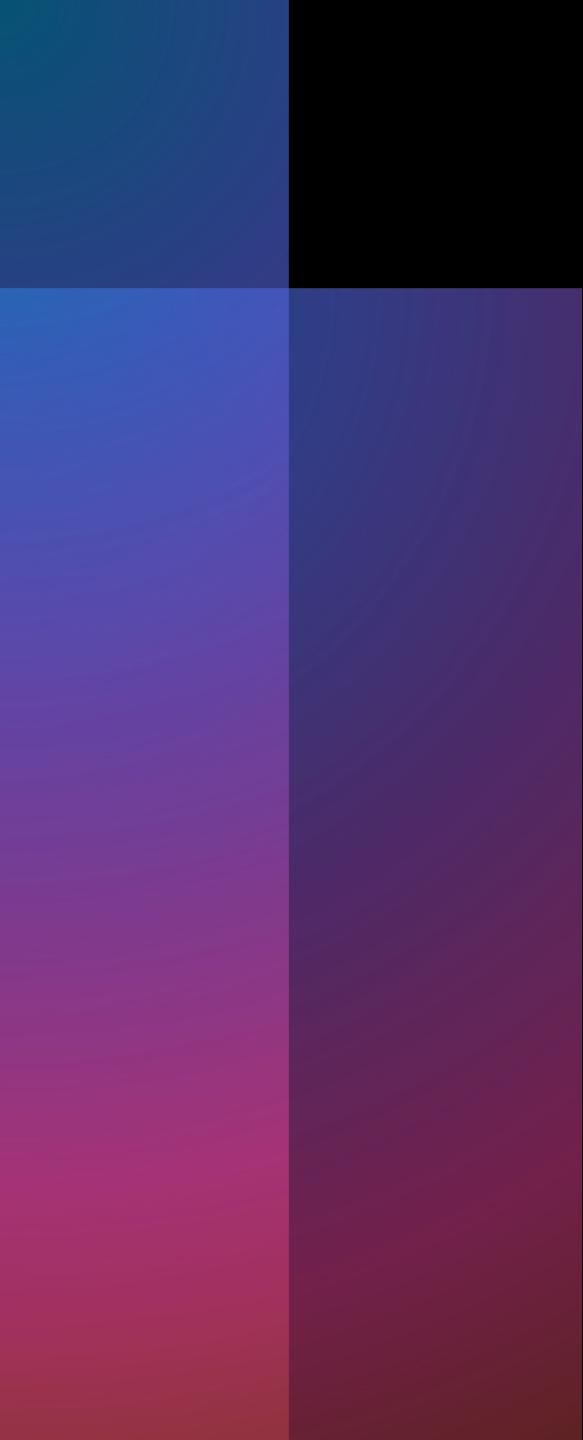


# Ressourcen zu diesem Kapitel und AI:

- <https://www.elementsofai.com/>
- [https://www.youtube.com/watch?v=G3YO0C\\_FDKA](https://www.youtube.com/watch?v=G3YO0C_FDKA)
- <https://www.ibm.com/cloud/learn/what-is-artificial-intelligence>
- <https://www.euronews.com/next/2021/12/01/france-approves-fully-autonomous-bus-for-driving-on-public-roads-in-a-european-first>

# Ressourcen zu diesem Kapitel und AI:

- <https://ahistoryofai.com/antiquity/>
- <https://news.stanford.edu/2019/02/28/ancient-myths-reveal-early-fantasies-artificial-life/>
- <https://www.heise.de/hintergrund/Kybernetisches-Hirn-Implantat-schaltet-Schmerzen-automatisch-ab-6133744.html>
- <https://de.wikipedia.org/wiki/McCulloch-Pitts-Zelle>
- <https://www.bnbbloomberg.ca/google-has-more-pressing-ai-problems-than-sentient-bots-1.1778776>



# 1.4 Machine Learning

# 1.4.1 Warum Machine Learning?

- Der Begriff “**Machine Learning**” wurde von **Arthur Samuel 1959** in seiner Arbeit “*Some studies in machine learning using the game of checkers*” geprägt.
- **Klassisches Machine Learning benötigt Menschen bzw. menschliche Expertise**
- Spielt vor allem im Data Science Bereich eine sehr große Rolle, da durch statistische Methoden Algorithmen gut auf bestimmte Ziele hintrainiert werden können → dadurch **bessere Vorhersagen** oder **Klassifizierungen**
- Durch ML erhält man oft **tiefere Einblicke** und gewinnt **neue Erkenntnisse**
- Frameworks wie **PyTorch** und **TensorFlow** helfen, die Entwicklung zu erleichtern und so schneller zu Lösungen zu kommen

## 1.4.2 Key ML Terminology

- **Labels:** Das, was vorhergesagt wird. Ist meist das “y” in einer linearen Regression.  
Labels können zukünftige Preise sein, ein bestimmtes Tier in einem Foto – einfach alles, was vorhergesagt werden kann.
- **Features:** Sind die Inputvariablen, meist als “x” bezeichnet. Einfache Modelle haben ein Feature, “stärkere” Modelle können Millionen an Features haben. Diese werden mit  $x_1, x_2, \dots, x_n$  bezeichnet.

### Beispiel: Spam Detector

Ein Feature könnte ein bestimmtes **Wort in einer Email**, eine bestimmte **Absender:innenadresse**, der **Zeitpunkt des Versendens einer Mail**,... sein.

- **Models**: Definieren die Beziehung zwischen Features und Labels.  
Es gibt zwei wichtige Phasen: **Training und Inferenz**.

**Training**: Hier wird das Modell trainiert, es werden ihm **labeled Examples** gezeigt, von denen das Modell **graduell lernen** und die **Beziehung zwischen den Features und den Labels** “verstehen” kann

**Inferenz**: Trainiertes Modell wird auf **unlabeled Examples** “**losgelassen**”; die Vorhersage wird als **y'** bezeichnet

- **Regression:** Modell sagt kontinuierliche Werte voraus (damit sind “weiterzählbare” Werte gemeint, z. B. das Gewicht einer Person: 65,30203020... annehmen kann)
- **Classification:** Modell sagt diskrete Werte vorher (z. B. : Ist auf dem Bild eine Katze oder ein Hund zu erkennen?; sind kategorisierbare Werte → Ja/Nein-Werte)

- **Lineare Regression:**

$$y' = b + w_1 x_1$$

$y'$  ..... vorhergesagtes Label (also der gewünschte Output)

$b$  ..... Bias (aka der y-Achsenabschnitt der Regressionsgeraden)

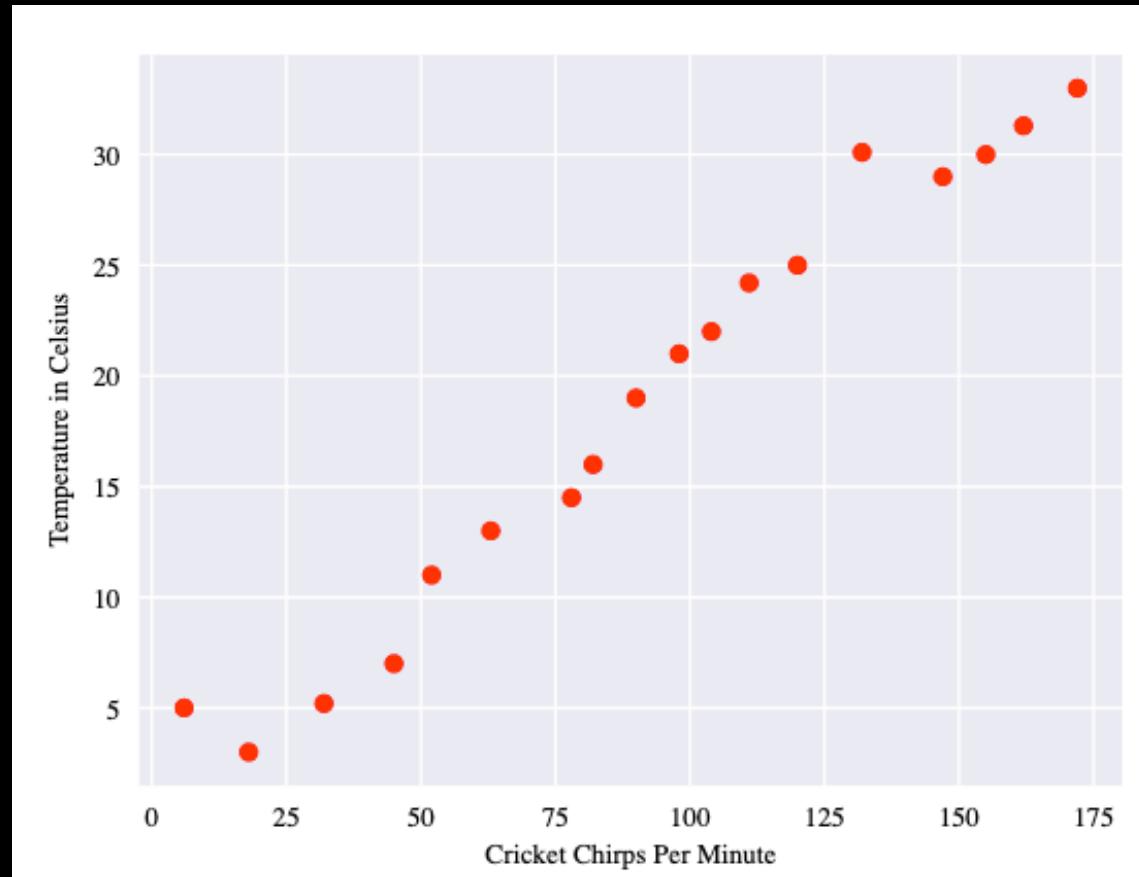
$w_1$  ... Gewicht von Feature 1

$x_1$  .... Feature (also bereits bekannter Input)

- **Weights**: Gewichte von Features. Erhalten meistens am Anfang einen **zufälligen Wert** (Forward Propagation), um sie quasi zu initialisieren und zu schauen, wie sich das Modell verhält. Werden anschließend angepasst. Die Differenz zwischen dem tatsächlichen Output und dem vorhergesagten wird hier auch Error genannt.
- **Loss-Function**: Damit kann man messen, **wie schlecht** ein ML-Modell tatsächlich ist, d. h. wie weit entfernt das Modell vom Label ist. Für ML-Modelle werden Loss-Funktionen im Vorfeld definiert; es gibt unterschiedliche für verschiedene Anwendungen.  
Für die lineare Regression verwendet man idR die **Mean Squared Error-Funktion**.

## 1.4.3 Lineare vs. Nicht-Lineare (Polynomiale) Regression

Lineare Regression:

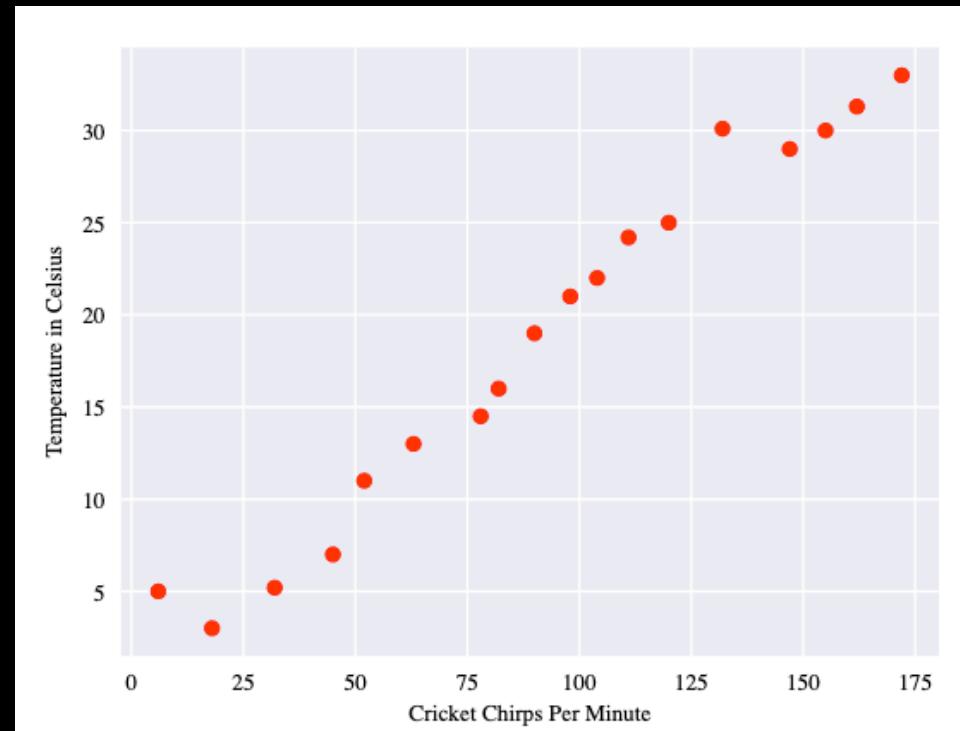


## 1.4.3 Lineare vs. Nicht-Lineare (Polynomiale) Regression

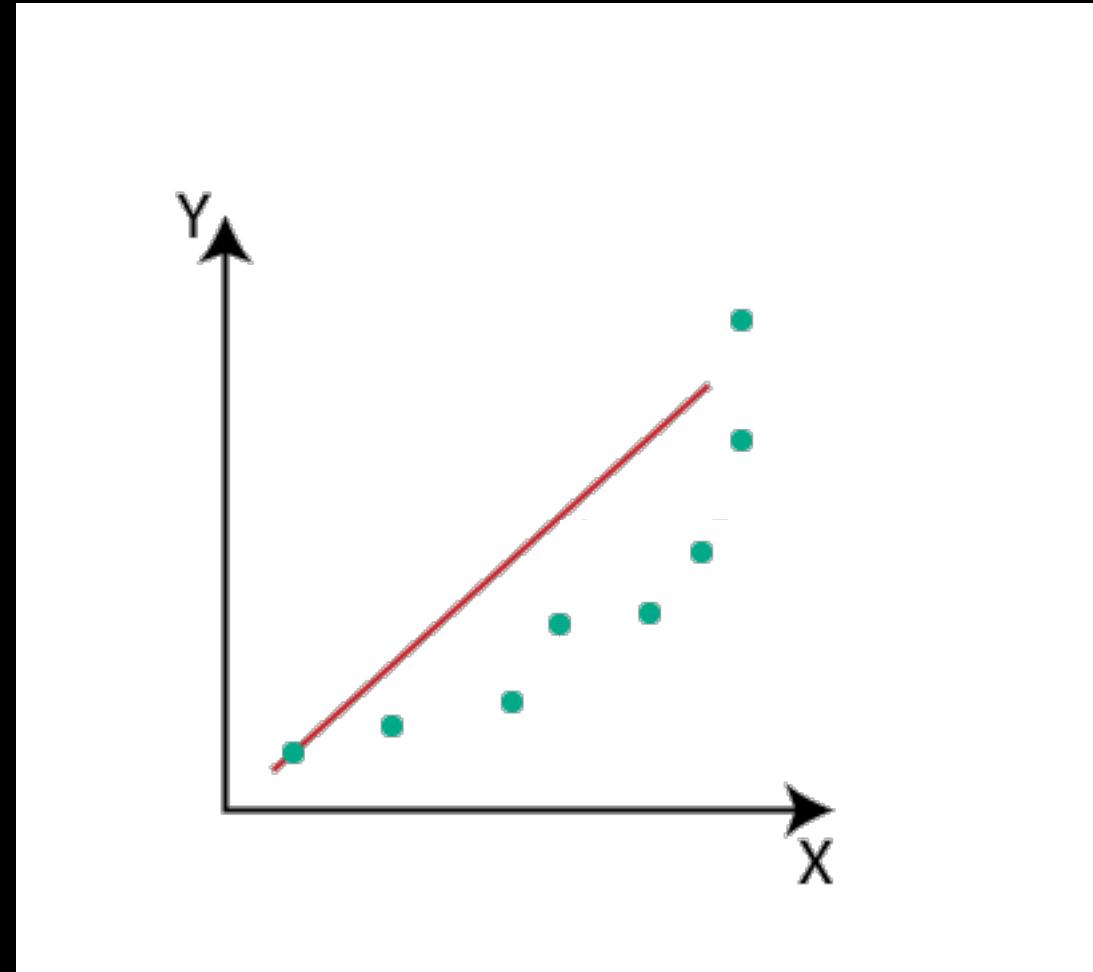
Lineare Regression:

$$y' = w_0 + w_1 x_1 + \dots + w_n x_n$$

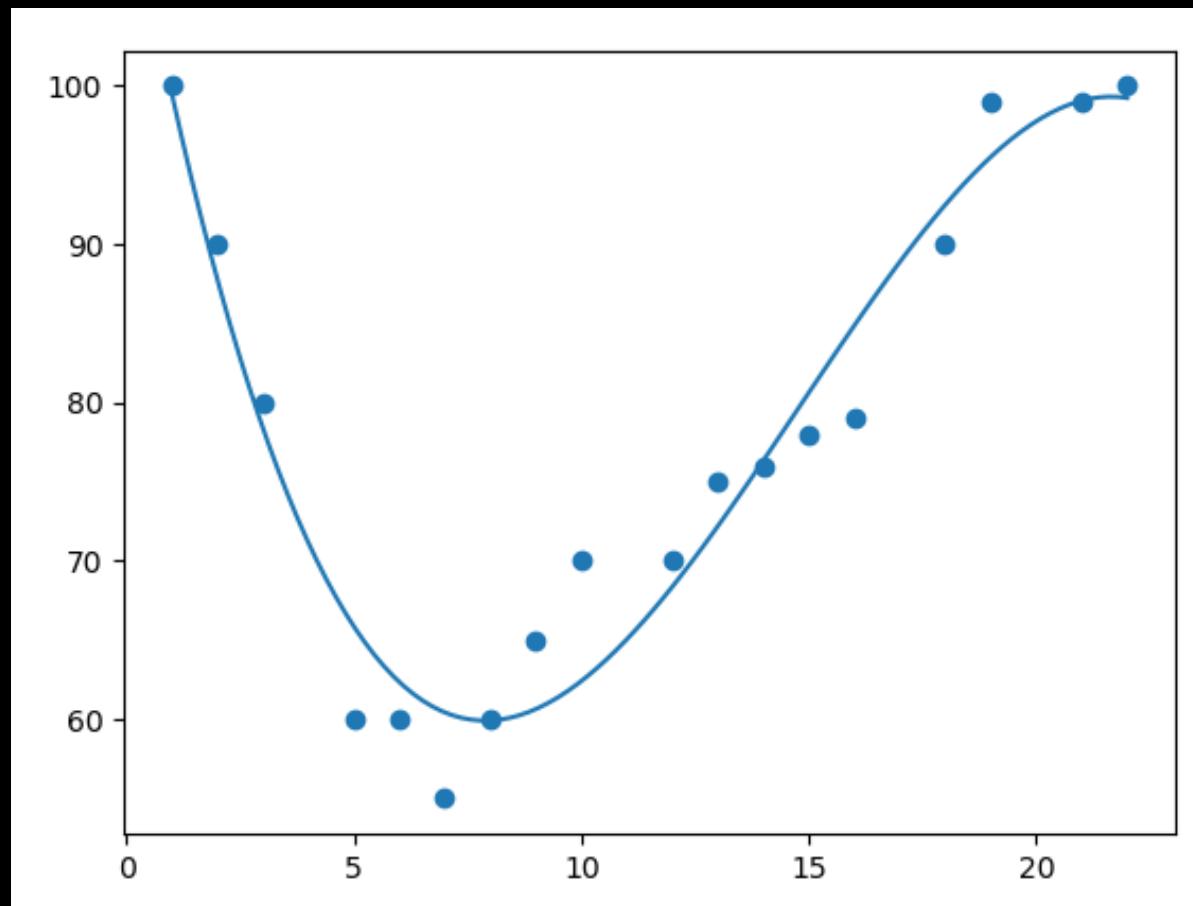
$y'$  ..... vorhergesagtes Label (also der gewünschte Output)  
b ..... Bias (aka der y-Achsenabschnitt der Regressionsgeraden)  
 $w_1$  ... Gewicht von Feature 1  
 $x_1$  .... Feature (also bereits bekannter Input)



# Bei solchen Problemen versagt die lineare Regression:

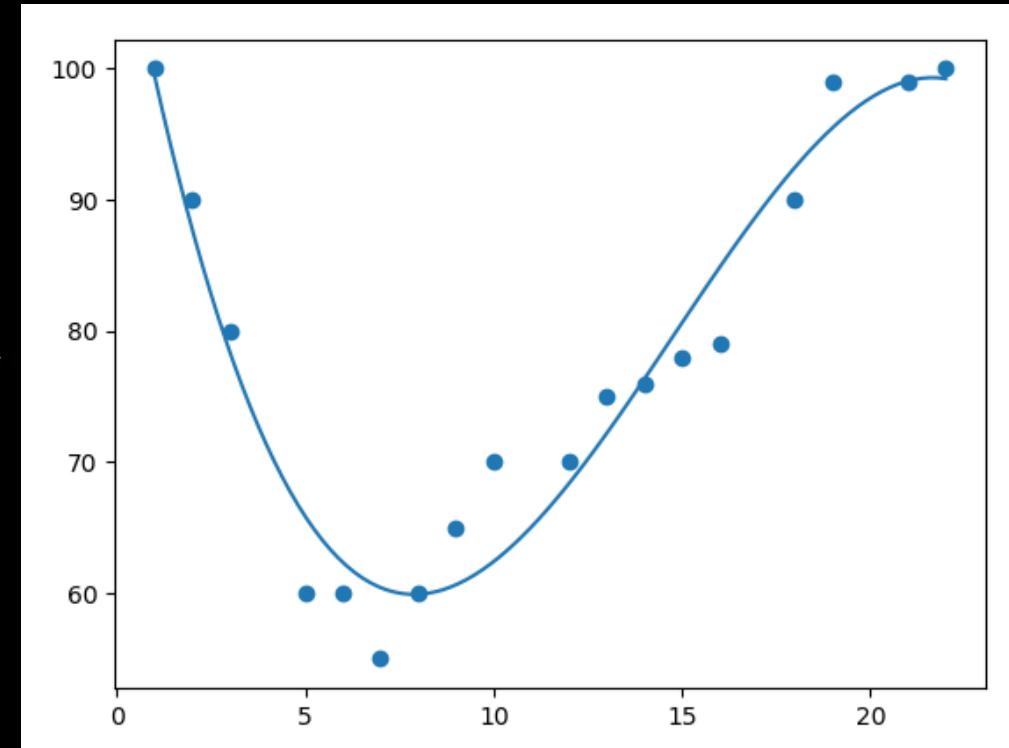
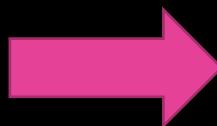


# Polynomiale Regression:



# Polynomiale Regression:

$$y' = w_0 + w_1 x_1^2 + \dots + w_n x_n^n$$

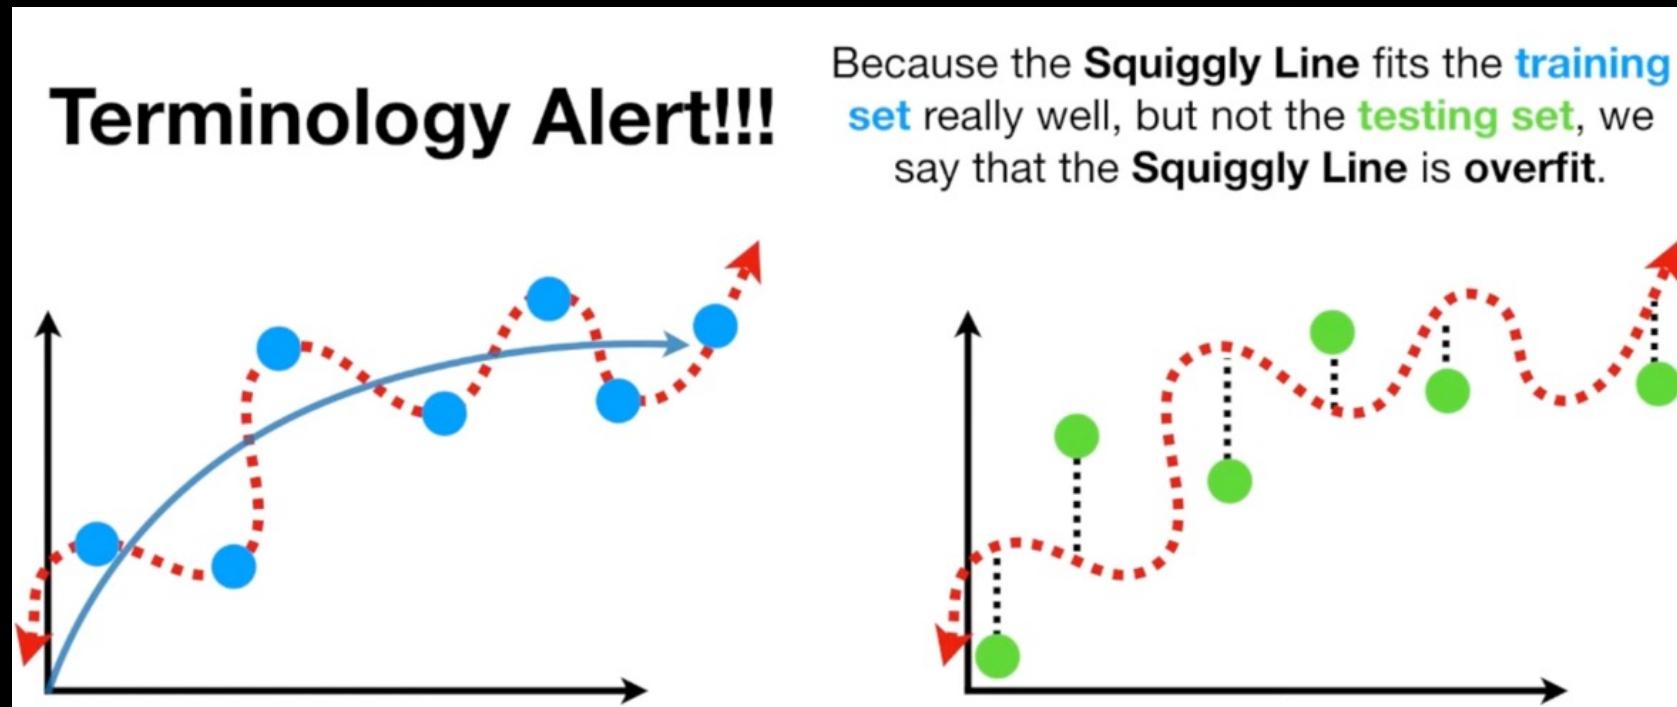


# ABER VORSICHT!

- Dadurch, dass wir unsere Linie nun auf die Daten anpassen können, kann es dazu kommen, dass wir “overfitten”.
- Wenn wir ein ML-Modell trainieren und ZU genau auf diese jeweiligen Daten fitten, schneidet es bei Test-Daten (also Inhalte, die das Modell nicht kennt; ”frischer Input”) höchstwahrscheinlich miserabel ab!

# Kurzer Exkurs zum Thema “Overfitting”

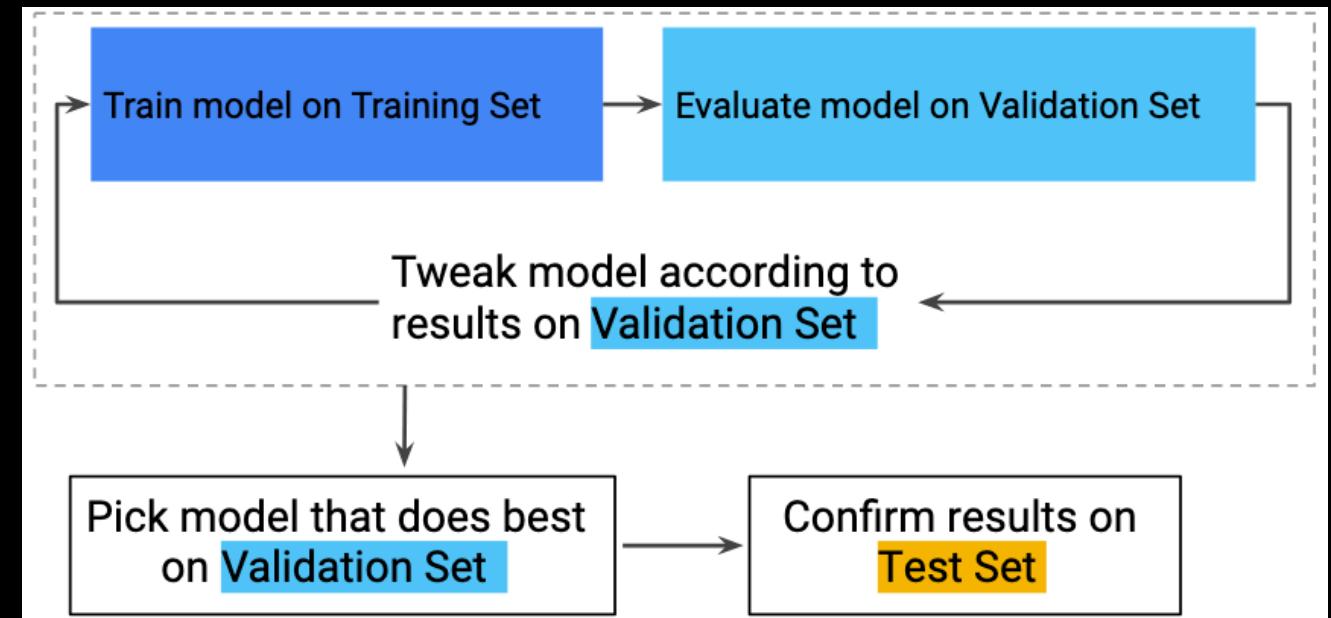
- Aus dem Buch von University Professor und Youtuber “Statquest”  
Josh Starmer:



**“Overfitting occurs when a model tries to fit the training data so closely that it does not generalize well to new data.”**

Daher:

Ein ausreichend **großes, statistisch aussagekräftiges Data set** verwenden, welches man in **Trainings-, Validierungs- und Testset aufsplitten** kann!



# 1.4.4 Lernflow von ML

- Kann unterteilt werden in drei Hauptabschnitte:
- **1. Der Entscheidungsprozess:**  
Modell wird trainiert, um eine Vorhersage zu treffen oder Klassifizierung vorzunehmen.
- **2. Error-Funktion:**  
Damit evaluiert man die Vorhersagefähigkeit des Modells.
- **3. Modell-Optimierungsprozess:**  
Füttet ein Modell besser auf die Trainingsdaten, müssen die Gewichte angepasst werden, um die Diskrepanz zwischen bekanntem Example und Modell-Vorhersage zu reduzieren.

# 1.4.5 Machine Learning Methods

- **Supervised Learning:**

Datensets sind gelabeled, und Algorithmus wird darauf trainiert, bestimmte Dinge zu klassifizieren oder vorherzusagen. Lineare Regression ist eine Supervised Learning Methode.

- **Unsupervised Learning:**

Genau das Gegenteil: Es existieren keine gelabelten Datensets, stattdessen soll das Modell Cluster bzw. Gruppen bilden, die Gemeinsamkeiten aufweisen

- **Semi-Supervised Learning:**  
Eine Mischung aus den beiden oben genannten Methoden.
- **Reinforcement Learning:**  
Ähnelt Supervised Learning, nur gibt es keine Sample-Daten, auf die trainiert werden. Stattdessen soll ML-Modell nach dem Trial-and-Error-Prinzip lernen. Erfolge werden belohnt, Misserfolge bestraft.

## 1.4.5 Einführungsbeispiele

- [https://colab.research.google.com/github/google/eng-edu/blob/main/ml/cc/exercises/pandas\\_dataframe\\_ultraquick\\_tutorial.ipynb](https://colab.research.google.com/github/google/eng-edu/blob/main/ml/cc/exercises/pandas_dataframe_ultraquick_tutorial.ipynb)
- <https://colab.research.google.com/notebooks/charts.ipynb>
- [https://colab.research.google.com/github/google/eng-edu/blob/main/ml/cc/exercises/linear\\_regression\\_with\\_synthetic\\_data.ipynb](https://colab.research.google.com/github/google/eng-edu/blob/main/ml/cc/exercises/linear_regression_with_synthetic_data.ipynb)

# Ressourcen zu diesem Kapitel und Machine Learning:

- [https://hci.iwr.uni-heidelberg.de/system/files/private/downloads/636026949/report\\_frank\\_gabel.pdf](https://hci.iwr.uni-heidelberg.de/system/files/private/downloads/636026949/report_frank_gabel.pdf)
- <https://medium.com/towards-data-science/the-7-steps-of-machine-learning-2877d7e5548e>
- <https://www.ibm.com/cloud/learn/machine-learning>
- <https://developers.google.com/machine-learning/crash-course>
- <https://developers.google.com/machine-learning/glossary#label>
- <https://www.youtube.com/c/joshstarmer>

# Ressourcen zu diesem Kapitel und Machine Learning:

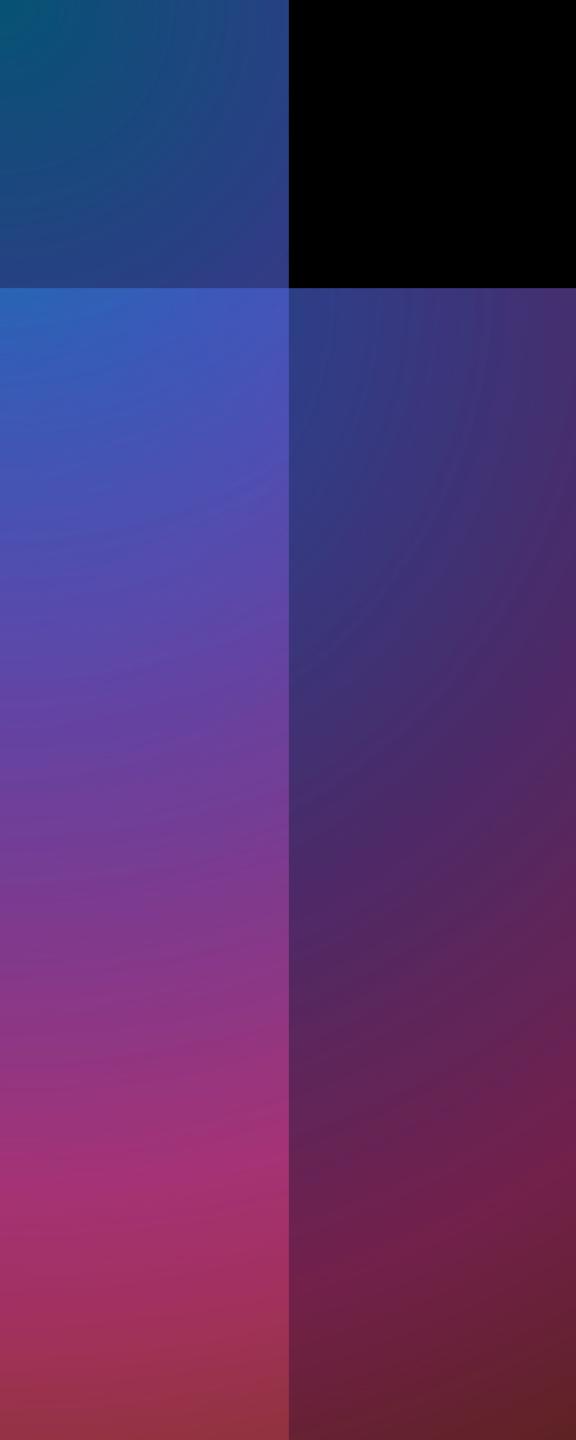
- <https://www.w3schools.com/python/numpy/default.asp>
- <https://www.w3schools.com/python/pandas/default.asp>
- [https://www.w3schools.com/python/matplotlib\\_intro.asp](https://www.w3schools.com/python/matplotlib_intro.asp)
- [https://www.w3schools.com/python/python\\_ml\\_getting\\_started.asp](https://www.w3schools.com/python/python_ml_getting_started.asp)
- [https://www.w3schools.com/ai/ai\\_tensorflow\\_intro.asp](https://www.w3schools.com/ai/ai_tensorflow_intro.asp)
- [https://colab.research.google.com/?utm\\_source=scs-index](https://colab.research.google.com/?utm_source=scs-index)

# Ressourcen zu diesem Kapitel und Machine Learning:

- <https://www.kaggle.com/learn>
- <https://stackoverflow.com/questions/3584805/in-matplotlib-what-does-the-argument-mean-in-fig-add-subplot111>
- <https://viso.ai/deep-learning/adversarial-machine-learning/>
- <https://youtu.be/VtRLrQ3Ev-U>

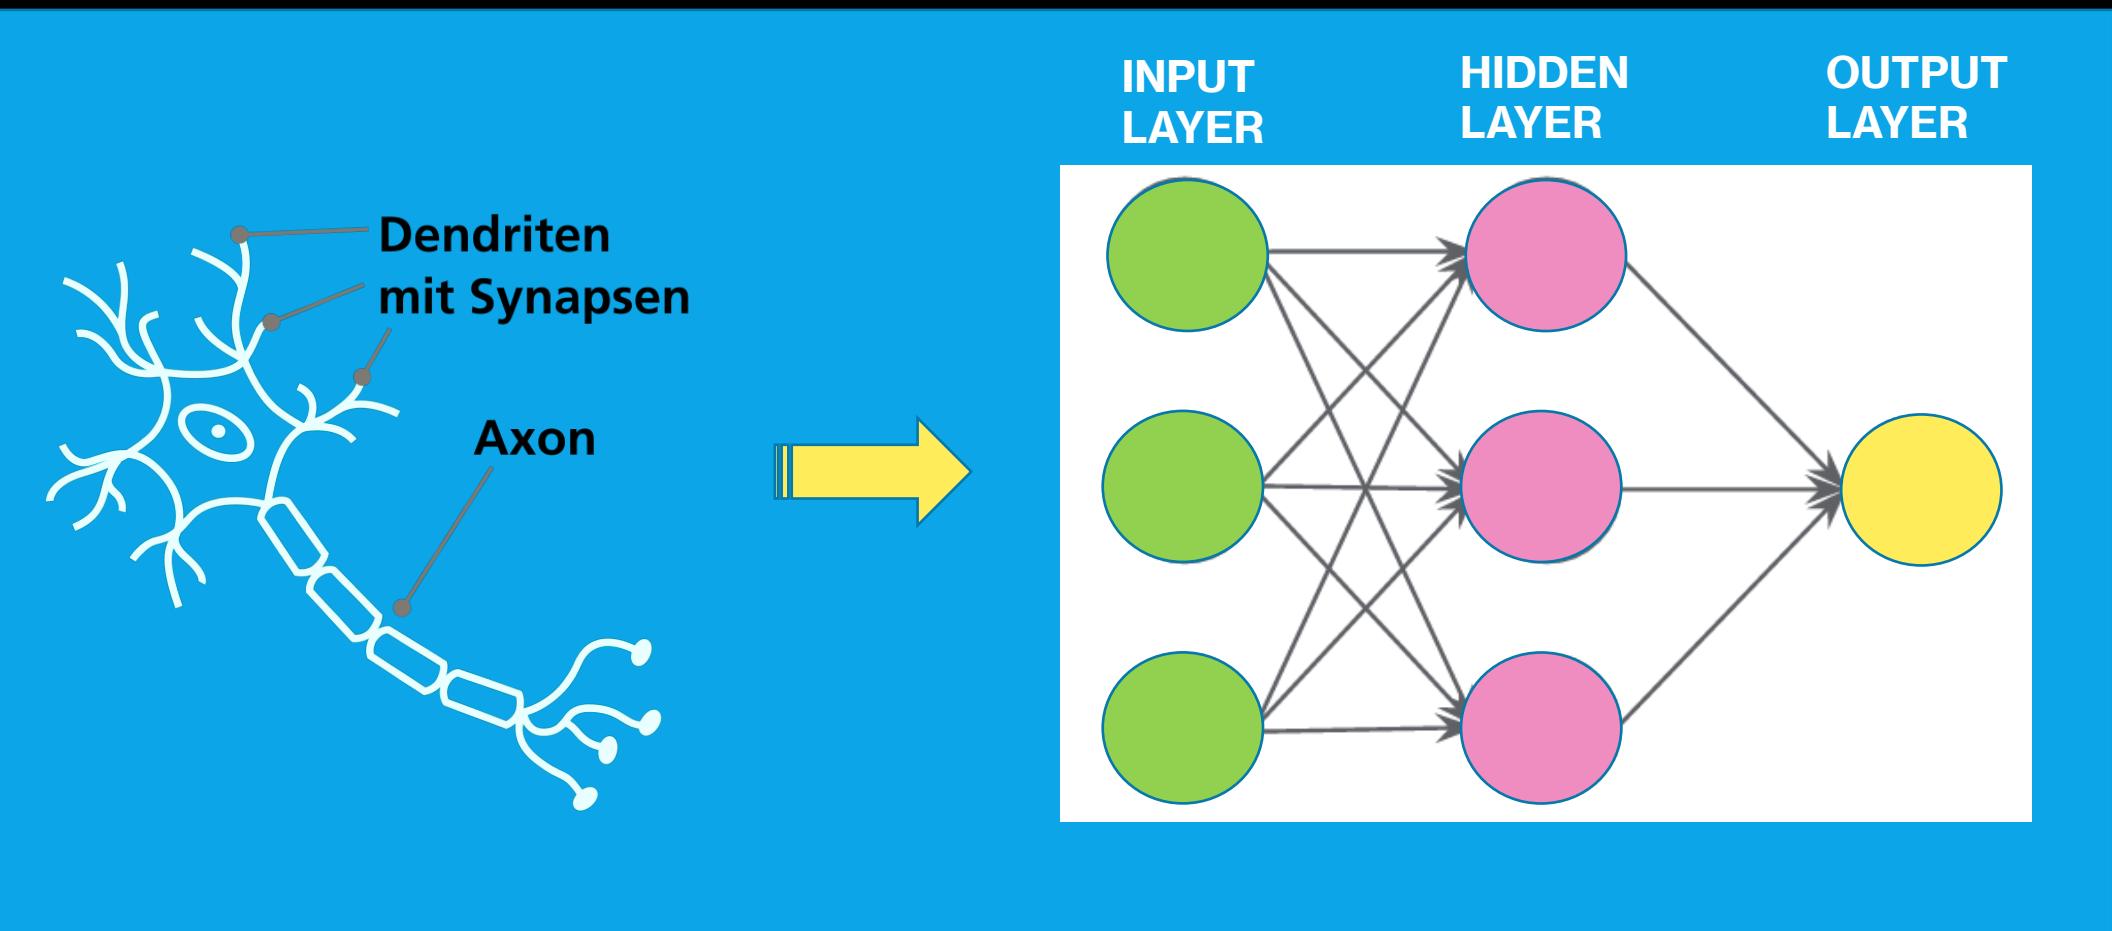
# PAUSE ☺



A vertical color bar on the left side of the slide, featuring a gradient from blue at the top to red at the bottom.

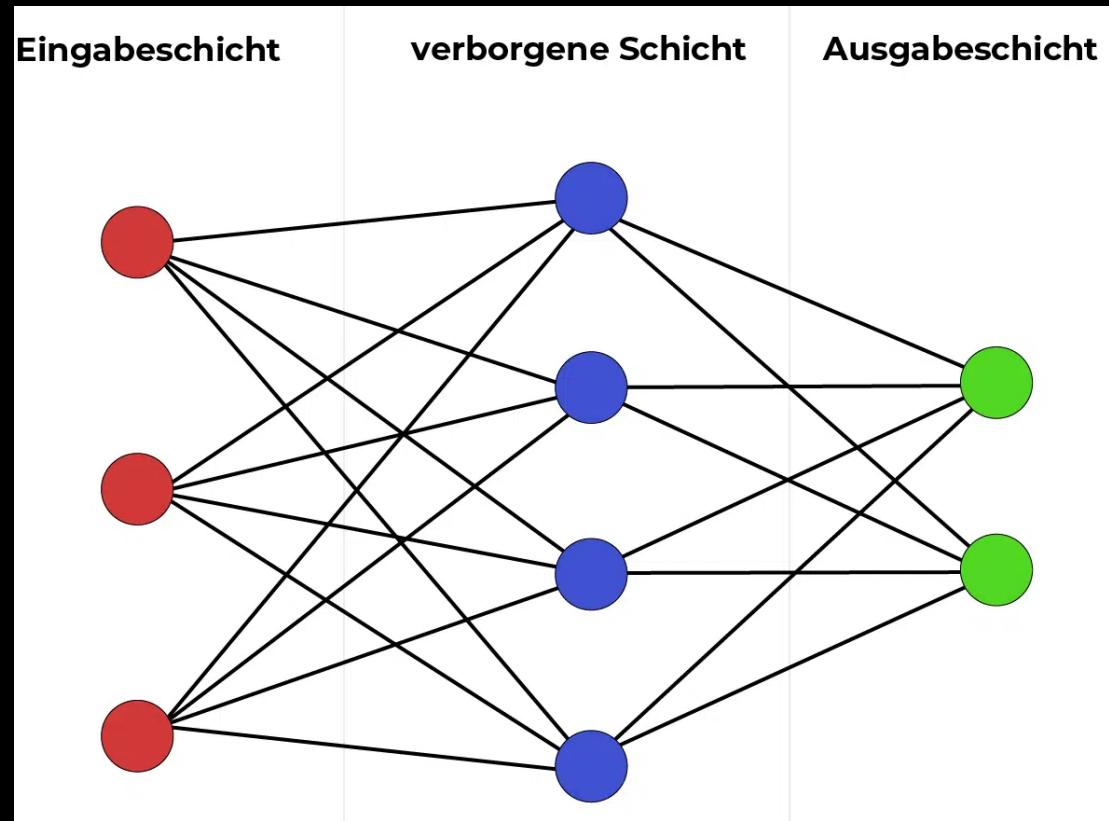
# 1.5 Deep Learning & Neural Networks

## 1.5.1 Künstliche vs. Biologische Neuronale Netzwerke



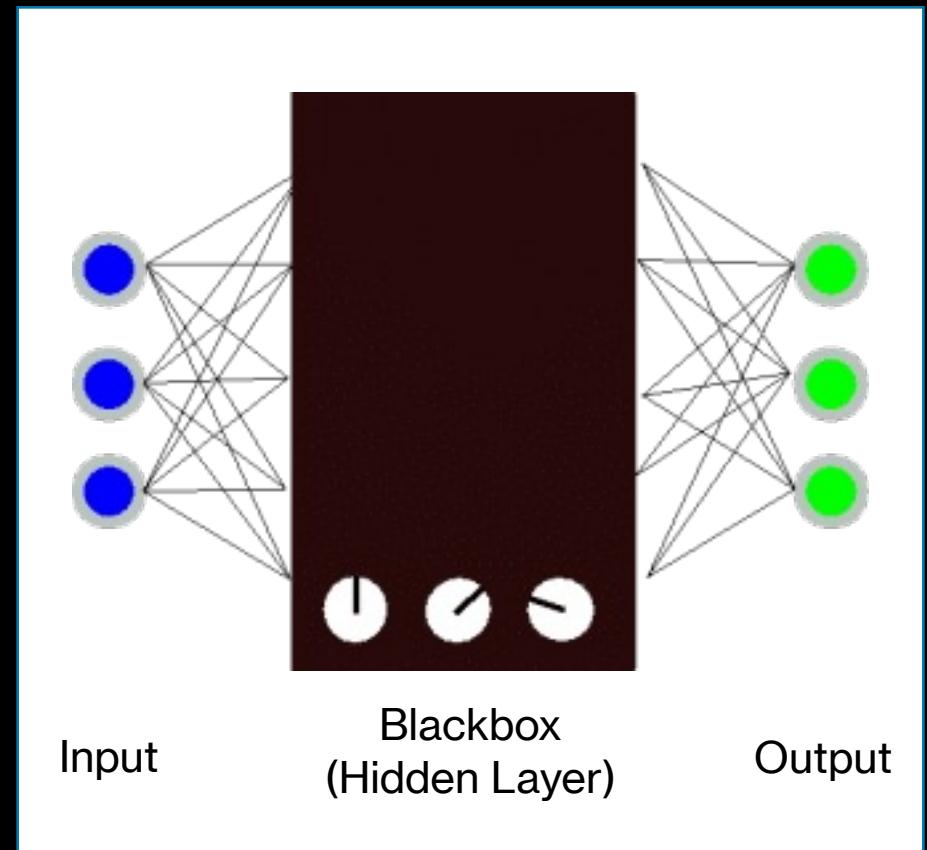
# Künstliche Neuronale Netzwerke

- **Künstliche Neuronale Netzwerke** basieren auf einem vereinfachten Modell unseres Gehirns, einem **biologischen neuronalen Netzwerk**
- **KNN**-Algorithmen werden für unterschiedliche Zwecke eingesetzt: Um Muster zu erkennen, zu klassifizieren, Cluster zu bilden,...
- KNNs bestehen immer aus einer **Eingabeschicht (= Input Layer(s))**, einer **verborgenen Schicht (= Hidden Layer(s))** und einer **Ausgabeschicht (= Output Layer(s))**

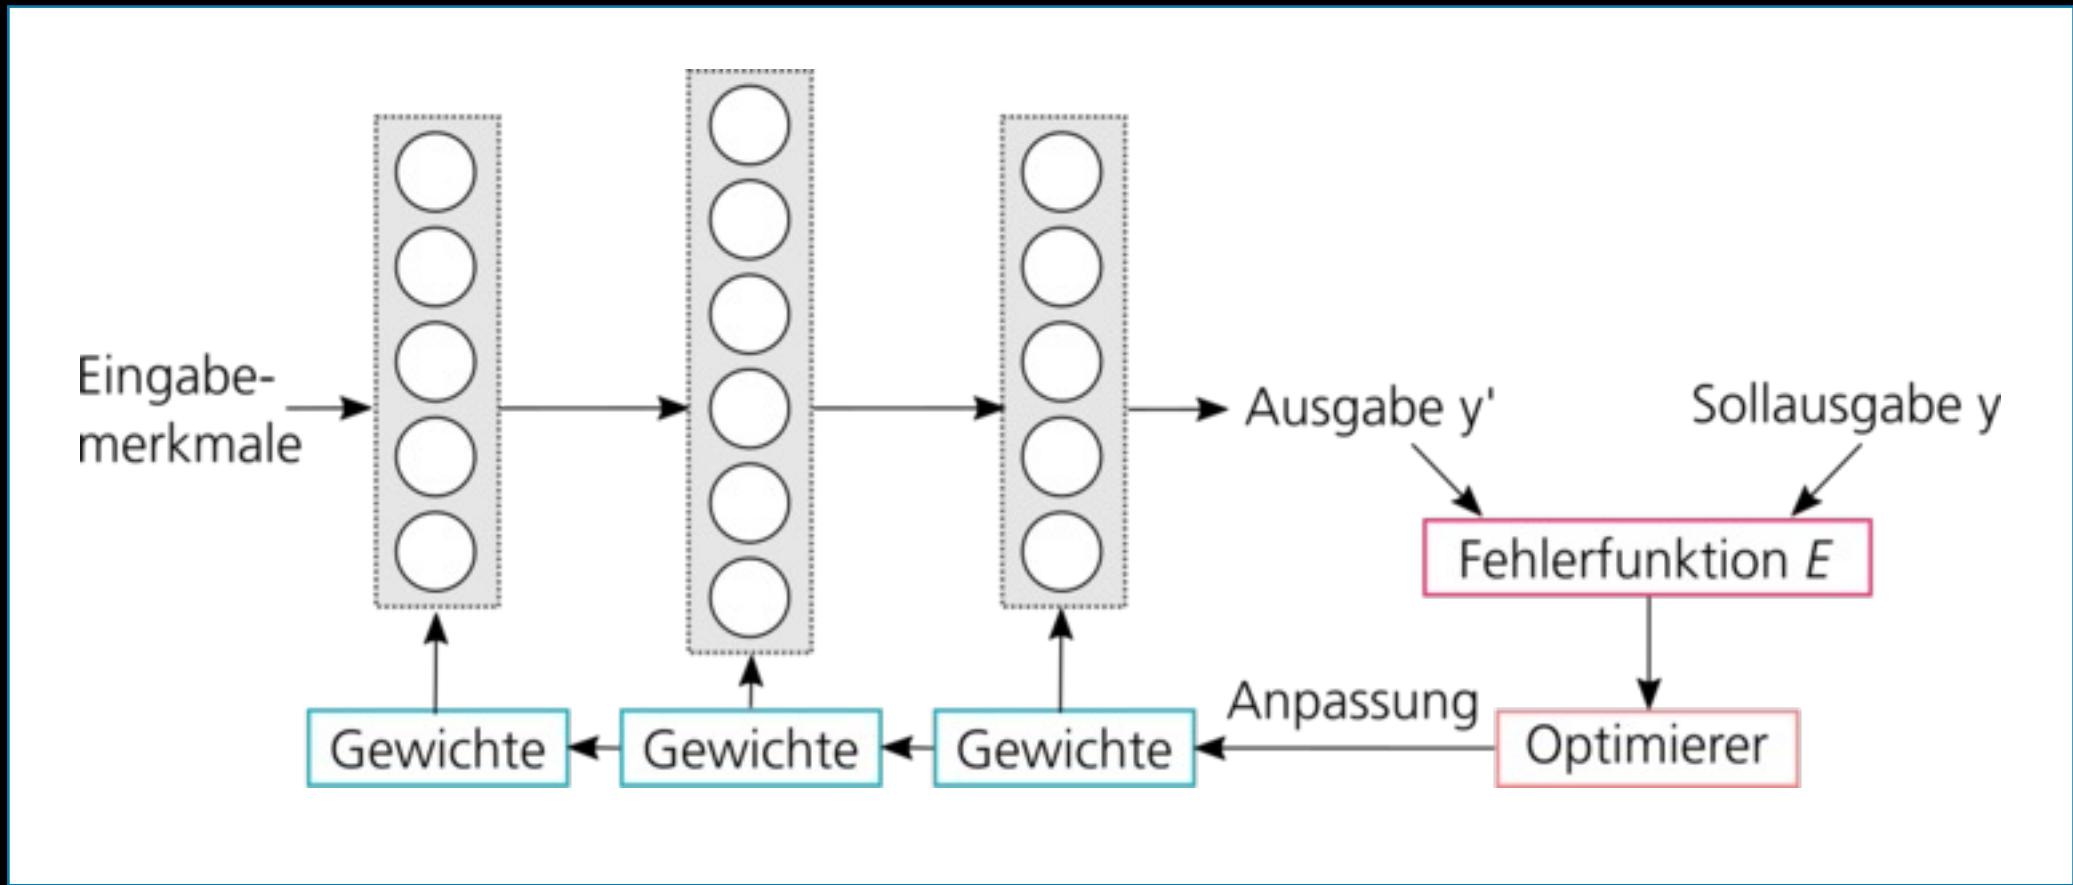


# Input-, Hidden- und Output-Layer

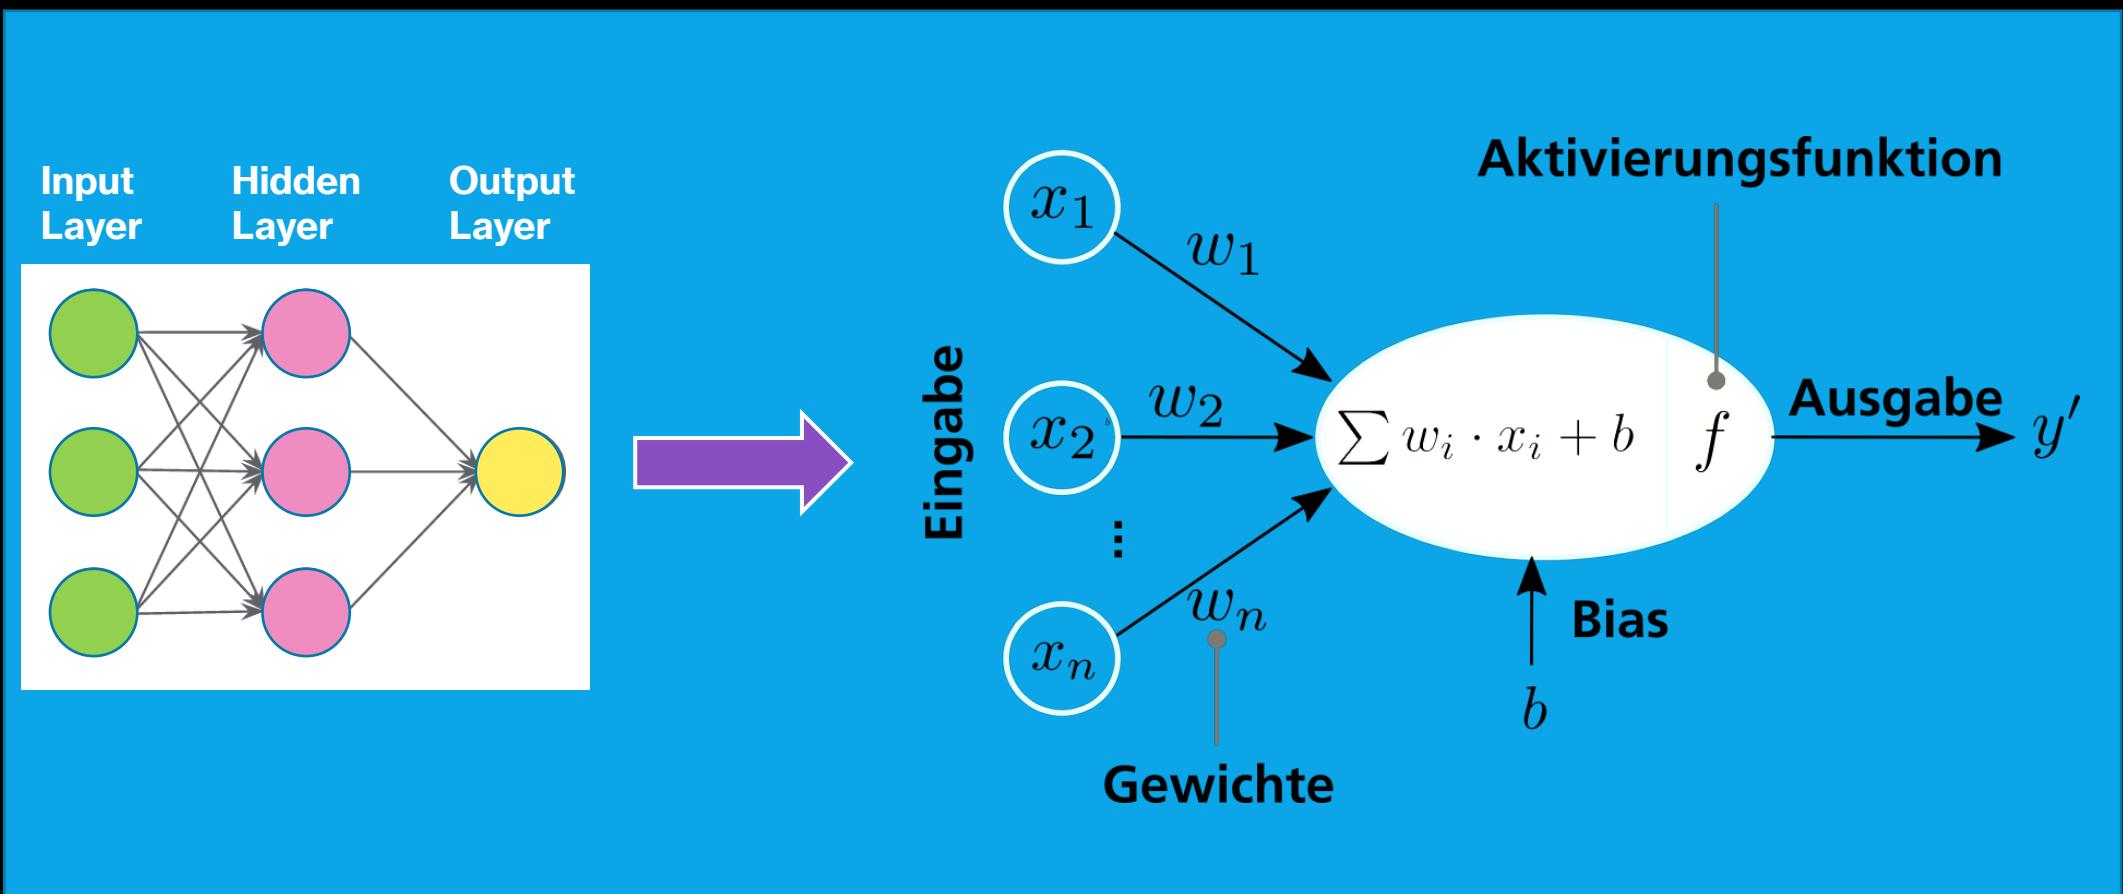
- **Input- und Output-Layer** sind für die Eingabe von Informationen bzw. Ausgabe dieser zuständig
- Die Hidden Layer bestehen aus **individuell gewichteten Neuronen**, die die **empfangene Information(en) ebenfalls gewichtet** werden, bevor sie in die nächste Schicht weitergegeben werden
- Die Komplexität steigt hier rasch an; man spricht dann von einem **“Blackbox Modell”**



# Input-, Hidden- und Output-Layer



# Berechnung von KNNs



## 1.5.2

**Komplex vs. Kompliziert**

# Kompliziert

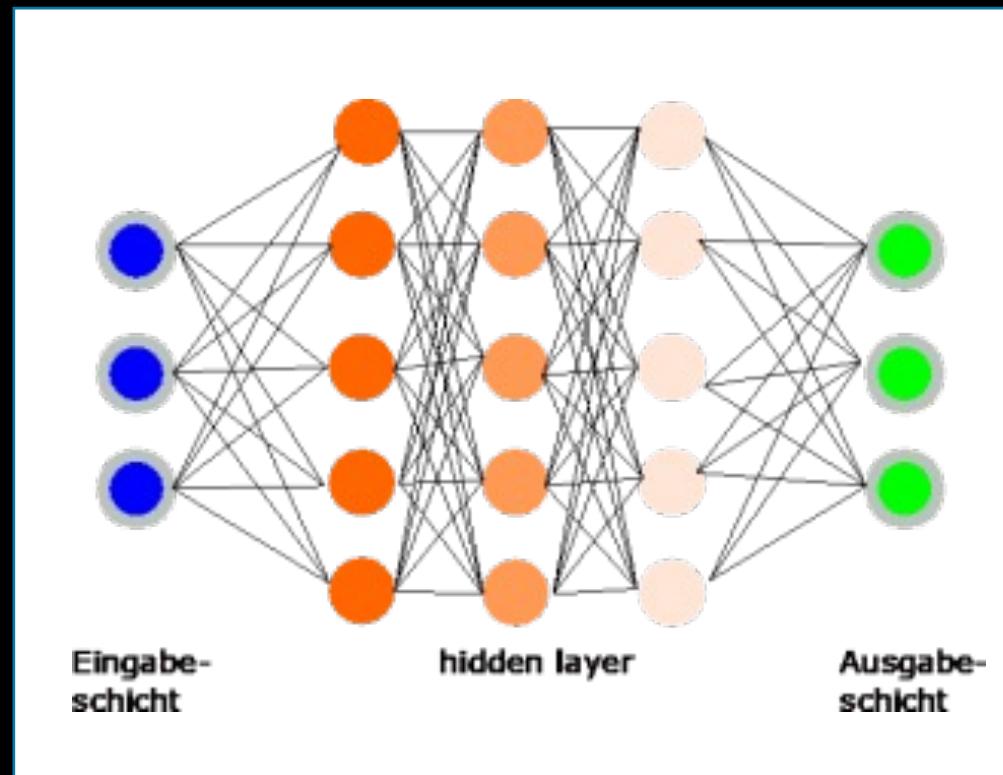
- Laut dem Duden ist etwas ***kompliziert***, wenn es “[aus vielen Einzelheiten bestehend und daher] schwer zu durchschauen und zu handhaben” ist
- Ein kompliziertes System ist eines mit vielen Bestandteilen, die idR deterministisch sind und über einen gewissen Zeitraum bestehen bleiben, wie sie sind
- Bsp.: Satelliten, Computer, Schweizer Uhrwerke,...

# Komplex

- Laut dem Duden beschreibt **komplex** ebenfalls etwas Vielschichtiges, etwas, das "*viele Dinge*" umfasst, "*nicht allein für sich*" auftritt, "*ineinandergreifend*", "*nicht auflösbar*" ist
- Komplexe Systeme haben idR viele, sich ständig verändernde Teile, die oft nicht-deterministisch sind – heißt, man kann ein komplexes System nur bis zu einem gewissen Grad "auswendig" lernen
- Bsp.: Organisches Systeme → menschliche Körper (Grundzüge kann man lernen, jeder Körper ist jedoch anders)

## 1.5.3 Deep Learning

- Deep Learning hat nichts mit “Tiefe” im Sinne eines tieferen Verständnisse für Probleme oder deren Lösungen zu tun
- ”Deep“ signalisiert, dass es sich bei einem KNN um ein Netzwerk handelt, welches viele (verdeckte) Schichten besitzt
- Je mehr verdeckte, also Hidden Layers, desto komplexer werden die Daten bearbeitet, extrahiert und dargestellt



- Es gibt keine pauschale Antwort darauf, wie viele Schichten/Neuronen “gut” sind und wie viele nicht → Ist derzeit noch Gegenstand der Forschung
- Zu wenig Neuronen können komplexe Sachverhalte nicht bearbeiten und somit kein hilfreiches Bild zu einem Problem liefern
- Zu viele Neuronen können jedoch rasch “overfitten” oder andere Probleme bereiten, die zu einem falschen oder verfälschten Ergebnis führen
- Dieses Problem wird als “Blackbox Modell” bezeichnet: Es gibt keine Transparenz darüber, wie ein KNN oder Deep Learning Modell zu einem Ergebnis kommt

## 1.5.4 Anwendungsgebiete

- GANs (Generative Adversarial Networks):  
<https://thispersondoesnotexist.com/>
- NLP (Natural Language Processing):  
<https://app.inferkit.com/demo>
- Selbstfahrende Autos
- Visuelle Erkennung
- Virtual/Personal Assistants wie Siri, Alexa, Google Assistant...

# Key Takeaways

- Biolog. NN sind deutlich komplexer und kompliziert als KNNs; Neue Studien zeigen, dass es **derzeit** ca. **1000 Layer** braucht, um **ein einziges biologisches Neuron** darzustellen
- Komplex ist etwas, wenn es viele Variablen beinhaltet und nicht auswendig gelernt werden kann;  
Kompliziert ist etwas, wenn es zwar aus vielen Teilen besteht, aber diese im Grunde unverändert bleiben und man es daher auswendig lernen kann
- Das “Deep” in Deep Learning bezieht sich auf die hohe Anzahl an Schichten und die Möglichkeit, komplexe Themen zu bearbeiten

# Ressourcen zu diesem Kapitel und KNNS/DL:

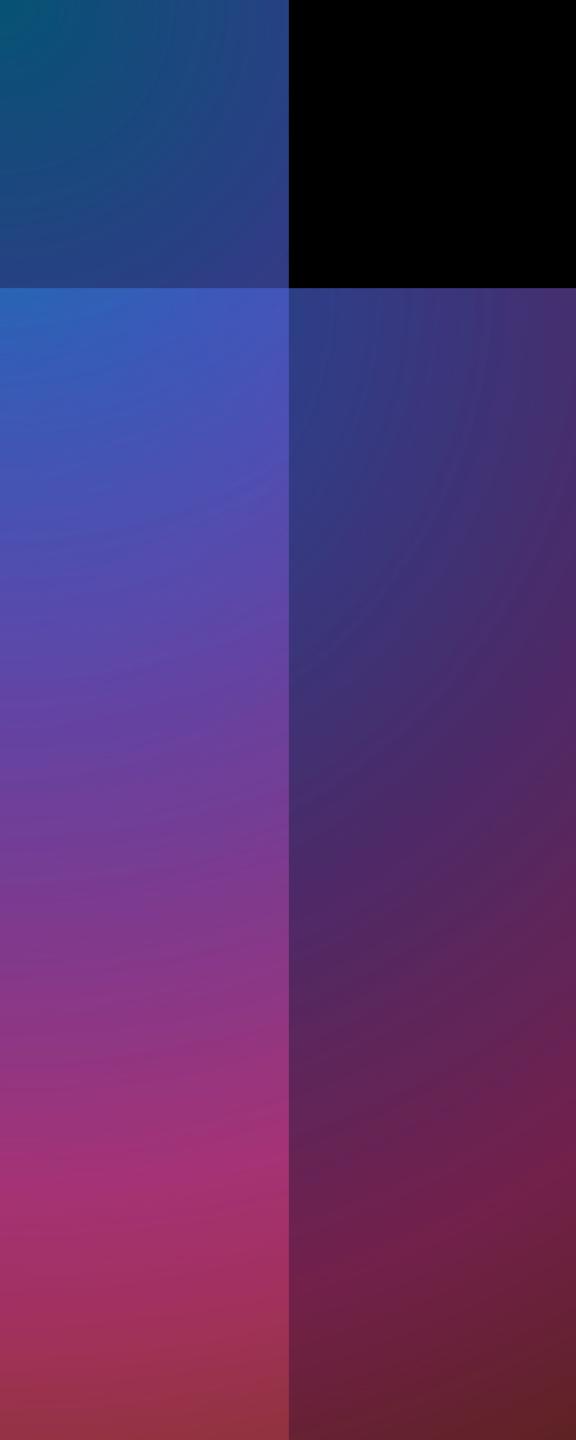
- <https://app.participate.com/communities/center-for-humanetechology/151c791f-4db4-4a31-b78e-5d5d64f72fea/courses>
- <https://www.krebsinformationsdienst.de/tumorarten/grundlagen/krebsentstehung.php>
- <https://www.youtube.com/watch?v=1AEIONvi9WQ>
- <https://studyflix.de/biologie/apoptose-2279>
- [https://www.researchgate.net/publication/354881743\\_Deep\\_learning\\_in\\_cancer\\_diagnosis\\_prognosis\\_and\\_treatment\\_selection](https://www.researchgate.net/publication/354881743_Deep_learning_in_cancer_diagnosis_prognosis_and_treatment_selection)

# Ressourcen zu diesem Kapitel und KNNS/DL:

- <https://www.dasgehirn.info/grundlagen/kommunikation-der-zellen/nervenzellen-im-gespraech>
- <https://towardsdatascience.com/everything-you-need-to-know-about-activation-functions-in-deep-learning-models-84ba9f82c253>
- <https://novustat.com/statistik-blog/kuenstliches-neuronales-netz-einfach-erklaert.html>
- <https://www.informatik-aktuell.de/betrieb/kuenstliche-intelligenz/neuronale-netze-ein-blick-in-die-black-box.html>
- <https://huggingface.co/>

# Ressourcen zu diesem Kapitel und KNNs/DL:

- <https://course.fast.ai/>
- <https://keras.io/about/> +  
[https://keras.io/examples/vision/mnist\\_convnet/](https://keras.io/examples/vision/mnist_convnet/)



# 2. Wissenschaft,

- In der Wissenschaft gibt es keinen Fixpunkt, wo plötzlich Wissen “da” ist
- Erkenntnisse und Entdeckungen bauen auf Wissen auf, das von vielen anderen Menschen generiert wurde
- Dazwischen kann es eine lange Phase des Forschens und Studierens geben – das können Monate, meist Jahre, oft Jahrzehnte oder sogar Jahrhunderte sein!
- **Bsp.:** Auch ein Herr Einstein baute auf bestehenden Erkenntnissen auf. Ebenso sind viele dieser Erkenntnisse und Entdeckungen in Kollaboration u.a. mit dessen Frau Mileva Marić<sup>1,2</sup>, diversen Freunden und Kollegen entstanden

---

<sup>1</sup>: [The Collaboration of Mileva Maric and Albert Einstein \(2015\): <https://arxiv.org/abs/1503.08020>](https://arxiv.org/abs/1503.08020)

<sup>2</sup>: Uni Heidelberg: Mileva Maric - Die fast vergessene Einstein

- **Fast niemand erfindet das Rad neu**
- Entweder versuchen wir, **Konzepte aus der Natur nachzuahmen** (Vgl. Neuronale Netze in Tieren und in Maschinen), oder wir möchten **neue Konzepte in unsere Welt bringen** (z. B. Erneuerbare Energien).
- Es ist kein Muss, die Geschichte einer Disziplin zu **kennen**, um diese zu **können**
- Allerdings hilft es beim Verständnis und bei vielen Problemstellungen, besonders im Bereich von Machine Learning

# 2.1 Der Fehler im System

# 2.1 Der Fehler im System

Wie Carl Sagan bereits in seinem Buch “The Demon Haunted World” schrieb:

*“Science is far from a perfect instrument of knowledge. It's just the best we have. [...]”*

*“Science invites us to let the facts in, even when they don't conform to our preconceptions. It counsels us to carry alternative hypotheses in our heads and see which best fit the facts. [...]”*

*“One of the reasons for its success is that science has built-in, error- correcting machinery at its very heart. [...]”*

*“Every time a scientific paper presents a bit of data, it's accompanied by an error bar - a quiet but insistent reminder that no knowledge is complete or perfect. [...]”*

*“Except in pure mathematics nothing is known for certain (although much is certainly false).”*

## 2.2 Datensätze

- Datensätze sind per Default fehlerbehaftet
- Man spricht hier auch von BIAS
- Ein Bias in ML ist das Auftreten eines beobachtbaren Ergebnisses, dass systematisch mit Vorurteilen behaftet ist, aufgrund von fehlerhaften Annahmen.
- Anders gesagt: Es gibt keine vollständig objektiv erfassbare Wahrheit  
→ Es gibt nie “die” oder “eine” Wahrheit!

## 1.2.1 Biases in ML

Wie kann ein solcher Bias sich nun in einem Datensatz äußern?

## 2.2.1 Biases in ML

- **Historical Bias:**

Das Umfeld, in welchem die Daten aufgenommen wurde, befand sich in einem fehleranfälligen, unausgeglichenen Zustand

- **Representation Bias:**

Datensatz repräsentiert eine oder mehrere Gruppen kaum oder gar nicht und verzerrt somit das Ergebnis des Modells

- **Measurement Bias:**

Die Richtigkeit der Daten unterscheidet sich zwischen den verschiedenen Gruppen

- **Aggregation Bias:**

Tritt auf, wenn unterschiedliche Gruppen nicht passend kombiniert werden → kommt häufig im medizinischen Bereich vor

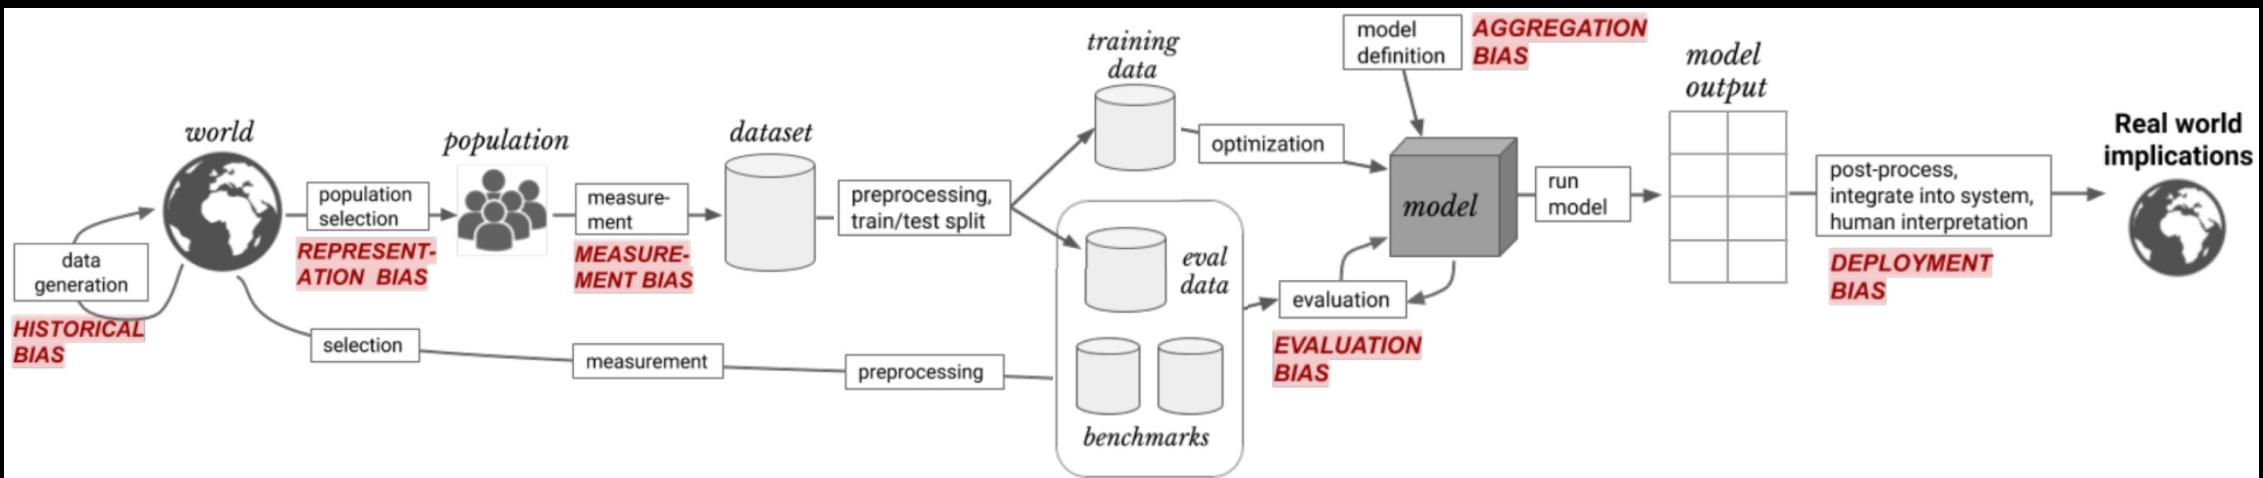
- **Evaluation Bias:**

Tritt auf, wenn Benchmark-Daten nicht die Population richtig repräsentieren können (d. h. es werden zwei Modelle miteinander verglichen, die ähnliche Tasks absolvieren)

- **Deployment Bias:**

Kommt dann vor, wenn das Modell ein Problem anders löst als es vorgesehen war. D. h. verwendet ein:e Endnutzer:in ein Modell nicht wie vorhergesehen, gibt es keine Garantie, dass das Modell gut performen wird

# 1.2.1 Biases in ML



Quelle: <https://www.kaggle.com/code/alexisbcook/identifying-bias-in-ai/tutorial>

Nun ein bisschen Praxis, damit wir uns das Ganze besser in  
“Code” vorstellen können ☺

## Kaggle - Identifying Bias in AI

# Ressourcen zu diesem Kapitel :

- <https://www.theverge.com/2018/1/12/16882408/google-racist-gorillas-photo-recognition-algorithm-ai>
- <https://towardsdatascience.com/bias-in-machine-learning-algorithms-f36ddc2514c0>
- <https://www.youtube.com/watch?v=162VzSzzoPs>
- <https://www.telusinternational.com/articles/7-types-of-data-bias-in-machine-learning>
- <https://www.bbc.co.uk/programmes/p09fy09f>
- <https://news.mit.edu/2022/machine-learning-biased-data-0221>

# Ressourcen zu diesem Kapitel :

- <https://www.nature.com/articles/s41591-022-01846-8>
- [https://www.theregister.com/2022/05/01/ai\\_models\\_racist/](https://www.theregister.com/2022/05/01/ai_models_racist/)
- <https://towardsdatascience.com/types-of-biases-in-data-cafc4f2634fb>
- <https://fortune.com/2022/05/03/eliminating-ai-bias-algorithms-difficult/>
- [https://www.tensorflow.org/responsible\\_ai](https://www.tensorflow.org/responsible_ai)
- <https://www.forbes.com/sites/quora/2017/07/24/what-should-beginners-know-about-adversarial-machine-learning/>

**Herzlichen Dank für  
eure Aufmerksamkeit!**

